



Hochschule für Angewandte Wissenschaften Hamburg
Hamburg University of Applied Sciences

Computational Intelligence

Prof. Dr.-Ing. Sabine Schumann

Fakultät Informatik und Digitale Gesellschaft

Soft Computing


Unsicheres Wissen

Was erwartet Dich in diesem Kapitel?

unsicheres Wissen

- Wahrscheinlichkeiten
- Bedingte Wahrscheinlichkeiten
- Bayessche Formel
- Sicherheitsfaktoren
- Bayessche Netze
- Naïve Bayes ➡ extra Kapitel

Was erwartet Dich in diesem Kapitel?



Wahrscheinlichkeiten (Vorwissen)

Bildquelle: <https://media1.britannica.com/eb-media/08/10408-004-0BCEF6E8.jpg>

Wahrscheinlichkeit

Eine Wahrscheinlichkeit drückt aus, mit welchem Maß man annehmen kann, dass ein Ereignis eintritt.

Beispiel:

Es wird mit einem Würfel eine gerade Zahl gewürfelt.

... hat eine Wahrscheinlichkeit von 0,5.

Wahrscheinlichkeiten können unterschiedlich interpretiert werden:

- Maß für die Häufigkeit von Ereignissen
- Subjektives Maß für das Eintreffen von Ereignissen

Wahrscheinlichkeit – Begriffe

- Wir haben also einen Ereignisraum Ω (frame of discernment).
in unserem Würfelbeispiel: $\Omega = \{1,2,3,4,5,6\}$
- und Elementarereignisse.
1, 2, 3, 4, 5, 6
- Jedes Ereignis ist darstellbar als: $A \subseteq \Omega$.
Ereignis: es wird eine gerade Zahl gewürfelt $A=\{2,4,6\}$
- Eine Aussage heißt wahr, wenn die der Aussage entsprechende Teilmenge das tatsächlich eingetretene Ereignis ω enthält: $\omega \in A$
- Menge aller möglichen Aussagen:
Menge aller Teilmengen von Ω bezeichnet als 2^Ω .
- Ω ist das sichere Ereignis
(da alle Elementarereignisse in Ω enthalten sind, $A = \Omega$)
- $\emptyset$ ist das unmögliche Ereignis, da die leere Menge kein Elementarereignis beinhaltet.

Wahrscheinlichkeit – Ereignisse und Logik


Ereignisse können **verknüpft** werden.

Sind A und B Ereignisse über dem Ereignisraum Ω , so sind es auch:

- $A \cap B$
Das Ereignis $A \cap B$ tritt genau dann ein,
wenn A eintritt **UND** auch B eintritt.
Das entspricht der Aussage **$A \wedge B$** .
- $A \cup B$
Analog entspricht das Ereignis $A \cup B$ der Aussage **$A \vee B$** .
- A^c (Mengenkomplement)
entspricht der Negation **$\neg A$** .

Wahrscheinlichkeit – Definition

Ereignissen sollen Zahlen $\in [0,1]$ zugeordnet werden, die einen **Erwartungswert** für deren Eintreffen darstellen, eine **Wahrscheinlichkeit**.



Andrei Nikolajewitsch Kolmogorov
(1903-1987)

Kolmogorov-Axiome 1933:

Sei Ω ein endlicher Ereignisraum.

Eine auf 2^Ω definierte Mengenfunktion

$P: 2^\Omega \rightarrow [0,1]$ heißt **Wahrscheinlichkeit**(sfunktion),
wenn gilt:

- $P(A) \geq 0$ für jedes beliebige Ereignis
- $P(\Omega) = 1$
- $P(A \cup B) = P(A) + P(B)$ für $A, B \subseteq \Omega$ mit $A \cap B = \emptyset$

paarweise disjunkt

Wahrscheinlichkeit – Eigenschaften

Für beliebige $A, B \subseteq \Omega$ gilt:

unmögliches Ereignis	$P(\emptyset) = 0$
Monotonie	$A \subseteq B \rightarrow P(A) \leq P(B)$
Subtraktivität	$A \subseteq B \rightarrow P(B \cap A^c) = P(B) - P(A)$
Subadditivität	$P(A \cup B) \leq P(A) + P(B)$
Additivität	$P(A \cup B) = P(A) + P(B) - P(A \cap B)$
Komplement	$P(A^c) = 1 - P(A)$

Was erwartet Dich in diesem Kapitel?

Wahrscheinlichkeiten

Bedingte Wahrscheinlichkeiten

Bayessche Formel

Bayessche Netze

Naïve Bayes ➡ extra Kapitel

... dann könnten wir ...!

Wenn das stimmt ...



Bilder: Freedigitalphotos.net: Renjith Krishnan, ID-10082483 und ID-10086282

Bedingte Wahrscheinlichkeit (1)

Meist sind jedoch abhängige Aussagen vorzufinden:

- *“Wenn ich die MMI-Klausur bestehe, dann gehe ich auf die Party.”*
- *“Wenn das Unternehmen X eine positive Jahresbilanz meldet, dann steigt die Unternehmens-Aktie um 5%”*



Was bedeutet ein Wert von 0.8 für diese Aussage?

Bedingte Wahrscheinlichkeit (2)

Betrachten wir

“Wenn das Unternehmen X eine positive Jahresbilanz meldet, dann steigt die Unternehmens-Aktie um 5%”

als logische Implikation:

$$A \Rightarrow B$$

so entspricht das

$$\neg A \vee B$$

Demzufolge bedeutet der Wert 0.8, dass in **80%** der Fälle das Unternehmen X keine positive Jahresbilanz meldet oder die Aktie um 5% steigt.



D.h. die 0.8 gelten für die gesamte Aussage.

Bedingte Wahrscheinlichkeit (3)

Mal als Beispiel anhand der Wahrheitstabelle:

positive Jahresbilanz (PJB)	Aktie steigt um 5% (AS5)	$\neg PJB \vee AS5$
F	F	W
F	W	W
F	F	W
F	W	W
F	F	W
W	F	F
W	F	F
W	W	W
F	W	W
F	W	W



Ist es das, was wir wollen???

Bedingte Wahrscheinlichkeit (4)

Formulieren wir die Aussagen nur leicht verändert, aber mit erheblichem semantischen Unterschied:

“Wenn ich die MMI Klausur bestehe, dann gehe ich sicherlich (0.75) auf die Party.”

“Wenn eine positive Jahresbilanz gemeldet wird, dann steigt die Aktie mit einer Wahrscheinlichkeit von 0.8 um 5%”

Solche Aussagen, im einfachsten Fall der Form

- if A then B with p oder auch
- $A \stackrel{p}{\Rightarrow} B$,

nennt man **bedingte Wahrscheinlichkeit**.

Bedingte Wahrscheinlichkeit (5) – Interpretation



Warum ist der Unterschied so erheblich?

“Wenn eine positive Jahresbilanz gemeldet wird, dann steigt die Aktie mit einer Wahrscheinlichkeit von 0.8 um 5%”

Betrachten wir das bisherige Beispiel:

- 7 mal keine positive Bilanz, 3 mal positive Bilanz
 - Aktie steigt in einem dieser 3 Fälle um 5%
- Erste Interpretation ($\neg A \vee B$):
0.8 **erfüllt** (logische Implikation ist in 8 von 10 Fällen wahr)
- Zweite Interpretation (bedingte Wahrscheinlichkeit $A \stackrel{p}{\Rightarrow} B$):
0.8 **nicht erfüllt** (Aktie stieg in nur 1 von 3 Fällen)

positive Jahresbilanz (PJB)	Aktie steigt um 5% (AS5)
W	F
W	F
W	W

Definition Bedingte Wahrscheinlichkeit

Sei B ein Ereignis mit $P(B) > 0$. Dann heißt

$$P(A/B) = \frac{P(A \cap B)}{P(B)}$$

bedingte Wahrscheinlichkeit von A unter der Bedingung B.

Falls $P(B) = 0$, ist die bedingte Wahrscheinlichkeit nicht definiert.

Bedingte Wahrscheinlichkeit – Beispiel



Beispiel:

Welchen Wahrscheinlichkeitswert erhält folgende Aussage:

“Wird eine gerade Zahl mit einem nicht manipulierten Würfel gewürfelt, dann ist es eine 6.”

Wahrscheinlichkeit

- für das Ereignis $GZ = \{2, 4, 6\}$:

$$P(GZ) = \frac{1}{2},$$

- für das Ereignis $Z = \{6\}$:

$$P(Z) = \frac{1}{6}.$$

Die bedingte Wahrscheinlichkeit für die obige Fragestellung:

$$P(Z/GZ) = \frac{P(Z \cap GZ)}{P(GZ)} = \frac{P(\{6\} \cap \{2, 4, 6\})}{1/2} = \frac{P(\{6\})}{1/2} = \frac{1/6}{1/2} = \frac{1}{3}$$

Bedingte Wahrscheinlichkeit – Multiplikationsregel

Der Würfel ...

wenn eine gerade Zahl (GZ) gewürfelt wurde, ist nun bekannt

$$P(\{i\}) = P(\{i\} | \text{GZ})$$

$$P(\{1\}) = P(\{3\}) = P(\{5\}) = 0$$

$$P(\{2\}) = P(\{4\}) = P(\{6\}) = \frac{1}{3}$$

Durch Umstellen der Formel für bedingte Wahrscheinlichkeiten erhalten wir die **Multiplikationsregel** (auch Multiplikationssatz):

$$P(A/B) = \frac{P(A \cap B)}{P(B)} : \quad P(A \cap B) = P(A/B) * P(B)$$

Bedingte Wahrscheinlichkeit – allgemeine Multiplikationsregel

Wir stellen um:

$$P(A/B) = \frac{P(A \cap B)}{P(B)} : \quad P(A \cap B) = P(A/B) * P(B)$$

- Diese Formel lässt sich nun direkt erweitern, erstmal auf **3 Mengen**:

$$P(A_1 \cap A_2 \cap A_3) = P(A_1) * P(A_2/A_1) * P(A_3/A_1 \cap A_2)$$

- Generalisierung auf **n Mengen**: **allgemeine Multiplikationsregel** (auch Verkettungsregel)
Gegeben sind die Ereignisse $A_1, \dots, A_n \subseteq \Omega$ mit $P(A_1 \cap \dots \cap A_{n-1}) > 0$, dann gilt:

$$P(A_1 \cap \dots \cap A_n) = P(A_1) * P(A_2/A_1) * P(A_3/A_1 \cap A_2) * \dots * P(A_n/A_1 \cap \dots \cap A_{n-1})$$

oder anders $\prod_{i=1}^n P(A_i | A_1 \cap \dots \cap A_{i-1})$

Was erwartet Dich in diesem Kapitel?

Wahrscheinlichkeiten

Bedingte Wahrscheinlichkeiten

Bayessche Formel

Bayessche Netze

Naïve Bayes ➡ extra Kapitel



Bildquelle: https://upload.wikimedia.org/wikipedia/commons/d/d4/Thomas_Bayes.gif

Deduktion und Induktion

Bei der **Deduktion** wird aus einem eingetretenen Ereignis auf ein davon abhängiges Ereignis geschlossen.

Bei der **Induktion** wird aus einem eingetretenen Ereignis auf ein erzeugendes Ereignis zurück geschlossen.

Bayessche Formel

Erneut:

Umstellen der Formel für bedingte Wahrscheinlichkeiten

$$P(A/B) = \frac{P(A \cap B)}{P(B)} : P(A \cap B) = P(A/B) * P(B)$$

Betrachten wir nun die bedingte Wahrscheinlichkeit von B unter der Bedingung A, erhalten wir:

$$P(B \cap A) = P(B/A) * P(A)$$

Der Mengendurchschnitt ist kommutativ ...

$$P(B) * P(A/B) = P(A) * P(B/A)$$

... und wir erhalten die **Bayessche Formel**:

$$P(A/B) = \frac{P(B/A) * P(A)}{P(B)}$$

Mit der Bayesschen Formel kann von einem eingetretenen Ereignis auf ein erzeugendes Ereignis geschlossen werden (Induktion).



Thomas Bayes
170?-1761

Bildquelle: https://upload.wikimedia.org/wikipedia/commons/d/d4/Thomas_Bayes.gif

Bayessche Formel - Akku-Beispiel I (1)

aus Boersch, Heinsohn, Socher: Wissensverarbeitung, Spektrum Verlag

akkubetriebener autonomer Roboter, dessen Fehlerrate vom Ladezustand des Akkus abhängt.
schwacher Akku – Fehlerrate nimmt drastisch zu
Erfahrungen der letzten Wochen:

- ➔ Der Roboter macht bei ca. 20% seiner Aktionen Fehler.
 $P(\text{Fehler}) = 0.2$
- ➔ Bei schwachem Akku steigt die Fehlerrate auf 80%.
 $P(\text{Fehler} \mid \text{schwach}) = P(\text{Fehler} \mid \text{nicht voll}) = 0.8$
- ➔ Im Durchschnitt ist der Akku in einer von 10 Minuten schwach.
 $P(\text{schwach}) = P(\text{nicht voll}) = 0.1$

? Wie hoch ist die Wahrscheinlichkeit, dass der Akku schwach ist, wenn bei einer Roboteraktion ein Fehler gemacht wird?

➔ wir suchen $P(\text{schwach} \mid \text{Fehler})$



Bildquelle: <http://vignette4.wikia.nocookie.net/starwars/images/1/1a/R2d2.jpg/revision/latest?cb=20090524204255>

Bayessche Formel - Akku-Beispiel I (2)

Bayessche Formel:

$$P(A/B) = \frac{P(B|A) * P(A)}{P(B)}$$

$$P(schwach/Fehler) = \frac{P(Fehler|schwach) * P(schwach)}{P(Fehler)}$$

$$P(schwach/Fehler) = \frac{0.8 * 0.1}{0.2} = \mathbf{0.4}$$

gegeben:

$$P(\text{Fehler}) = 0.2$$

$$P(\text{schwach}) = 0.1$$

$$P(\text{Fehler} \mid \text{schwach}) = 0.8$$

gesucht:

$$P(\text{schwach} \mid \text{Fehler})$$



Bildquelle: <http://vignette4.wikia.nocookie.net/starwars/images/1/1a/R2d2.jpg/revision/latest?cb=20090524204255>

Bayessche Formel - Akku-Beispiel II (1)

Aufgabenstellung leicht abgeändert!!!

akkubetriebener autonomer Roboter, dessen Fehlerrate vom Ladezustand des Akkus abhängt.
schwacher Akku – Fehlerrate nimmt drastisch zu
Erfahrungen der letzten Wochen:

➡ Der Roboter macht mit **vollem** Akku bei ca. 20% seiner Aktionen Fehler.

$$P(\text{Fehler} \mid \text{voll}) = 0.2$$

➡ Bei schwachem Akku steigt die Fehlerrate auf 80%.

$$P(\text{Fehler} \mid \text{schwach}) = P(\text{Fehler} \mid \text{nicht voll}) = 0.8$$

➡ Im Durchschnitt ist der Akku in einer von 10 Minuten schwach.

$$P(\text{schwach}) = P(\text{nicht voll}) = 0.1$$


? Wie hoch ist die Wahrscheinlichkeit, dass der Akku schwach ist, wenn bei einer Roboteraktion ein Fehler gemacht wird?

➡ wir suchen $P(\text{schwach} \mid \text{Fehler})$



Bildquelle: <https://s-media-cache-ak0.pinimg.com/736x/ef/0c/6a/ef0c6a7a8756482936443faadae15ecb.jpg>

Bayessche Formel - Akku-Beispiel II (2)



anders:

	v+	v-
f+	0.18	0.08
f-	0.72	0.02
	$P(v+) = 0.9$	$P(v-) = 0.1$

Bayessche Formel - Akku-Beispiel II (3)



Wie hoch ist die Wahrscheinlichkeit, dass der Akku schwach ist, wenn bei einer Roboteraktion ein Fehler gemacht wird?

Bayessche Formel:

- $P(A/B) = \frac{P(B|A) * P(A)}{P(B)}$

- $P(schwach/Fehler) = \frac{P(Fehler|schwach) * P(schwach)}{P(Fehler)}$

➔ $P(schwach/Fehler) = \frac{0.8 * 0.1}{0.26} = 0.31$

gegeben:

$$P(\text{Fehler} \mid \text{voll}) = 0.2$$

$$P(\text{schwach}) = 0.1$$

$$P(\text{Fehler} \mid \text{schwach}) = 0.8$$

errechnet:

$$P(\text{Fehler}) = 0.26$$

gesucht:

$$P(\text{schwach} \mid \text{Fehler})$$



Bildquelle: <https://s-media-cache-ak0.pinimg.com/736x/ef/0c/6a/ef0c6a7a8756482936443faadae15ecb.jpg>

Bayessche Formel ... und noch ein Beispiel

Wir betrachten ein Heimspiel von St. Pauli.

Wenn Pauli gewinnt oder unentschieden spielt, gibt es die nächste Eintrittskarte **günstiger**.

Wahrscheinlichkeit für den Ausgang eines Heimspiels von Pauli:

- Sieg: 0.85
- Unentschieden: 0.1
- Niederlage: 0.05

Wie hoch ist die Wahrscheinlichkeit, dass Pauli gewonnen hat, wenn wir für das nächste Heimspiel die **Karte günstiger** bekommen?

Wir suchen: $P(\text{Sieg} \mid \text{Karte günstiger})$

- $P(\text{Karte günstiger}) = 0.85 + 0.1 = 0.95$
- $P(\text{Sieg}) = 0.85$
- $P(\text{Karte günstiger} \mid \text{Sieg}) = 1$

$$P(\text{Sieg} \mid \text{Karte günstiger}) = \frac{P(\text{Karte günstiger} \mid \text{Sieg}) * P(\text{Sieg})}{P(\text{Karte günstiger})}$$

$$P(\text{Sieg} \mid \text{Karte günstiger}) = 1 * 0.85 / 0.95 = 0.8947 \approx \mathbf{0.89}$$

Beispiel (1)

Mitarbeiter*innen in einem Unternehmen:

Geschlecht	Arbeiter*in	Angestellte	total
m	1229	385	1614
w	42	341	383
d	2	0	2
total	1273	726	1999

Es wird zufällig ein / eine Mitarbeiter*in ausgewählt. Wir gehen davon aus, dass alle Mitarbeiter*innen die gleiche Chance haben, ausgewählt zu werden.

Wir interessieren uns für folgende Personen-Eigenschaften:

- A: Angestellte
- B: weiblich

Beispiel (2)

Wahrscheinlichkeit, dass ausgewählte/r Mitarbeiter*in

- Angestellte ist

$$P(A) = \frac{726}{1999} = 0,363...$$

- Weiblich ist


$$P(B) = \frac{383}{1999} = 0,192...$$

Geschlecht	Arbeiter*in	Angestellte	total
m	1229	385	1614
w	42	341	383
d	2	0	2
total	1273	726	1999

Unter der Bedingung, dass wir bereits wissen, dass der/die ausgewählte Mitarbeiter*in weiblich ist, können wir nun die bedingte Wahrscheinlichkeit ermitteln, dass es sich um eine Angestellte handelt:

$$P(A/B) = \frac{P(A \cap B)}{P(B)} = \frac{341/1999}{383/1999} = \frac{341}{383} = 0,89$$

Wahrscheinlichkeitsbaum



Unabhängigkeit von Ereignissen

Notationen:

- $A_1, \dots, A_n$ Variablen bzw. Ereignisse
- $\Omega_{A_1}, \dots, \Omega_{A_n}$ Wertebereich von A_i
- $a_1, \dots, a_n$ Elemente
- Variablen können Elemente oder auch Mengen von Elementen des Wertebereiches denotieren, bei wenigen Variablen wird auf die Indizierung verzichtet.
- Wenn für 2 Variablen A und B gilt: $P(A/B)=P(A)$, dann hat B anscheinend keinen Einfluss auf die Wahrscheinlichkeit von A, man bezeichnet A und B als **unabhängig**.
- Übertragen auf die Produkträume:
Zwei Ereignisse A und B heißen **statisch unabhängig**, wenn
$$P(A,B) = P(A/B) * P(B) = P(A) * P(B)$$

Beispiel Würfel:

Im ersten Versuch wird eine gerade Zahl gewürfelt (und) im zweiten Versuch wird eine ungerade Zahl gewürfelt.

$$P(A,B) = 0.5 * 0.5 = 0.25$$

Bedingte Unabhängigkeit von Ereignissen

Zwei Ereignisse A und B heißen **bedingt unabhängig** unter der Bedingung C, wenn

$$P(A, B | C) = P(A | C) * P(B | C)$$

es gilt auch:

$$P(A | B, C) = P(A | C)$$

Beispiel:

Fahrzeuge:

Typ (T) bestimmt Gewicht (G) und Benzinverbrauch (B).

Gewicht und Benzinverbrauch sind voneinander abhängig

$$P(G, B) \neq P(G) * P(B)$$

Wenn nun der konkrete Fahrzeugtyp bekannt ist, gilt obige Gleichung, d.h. bei bekanntem Fahrzeugtyp sind Gewicht und Benzinverbrauch unabhängig.

Interessiert mich das Gewicht des Fahrzeuges, benötige ich nur den Fahrzeugtyp, jedoch nicht den Benzinverbrauch ($P(G | B, T) = P(G | T)$)

☞ ausführlicher in Naïve Bayes

Bayessche Formel – Probleme

Es kann bei der Anwendung der Bayesschen Formel zu diversen Paradoxen kommen.



häufig sind die wahrscheinlichkeitstheoretischen Voraussetzungen nicht erfüllt bzw. prüfbar
widersprüchliche subjektive Werte können zu $P(A|B) > 1$ führen

- unabhängige vs. abhängige Ereignisse:
 - unabhängig:
Im ersten Versuch wird eine gerade Zahl gewürfelt (und)
im zweiten Versuch wird eine ungerade Zahl gewürfelt.
 $P = 0.5 * 0.5 = 0.25$
 - abhängig:
Im ersten Versuch wird eine gerade Zahl gewürfelt (und)
im ersten Versuch wird eine ungerade Zahl gewürfelt.
 $P = 0$ (beide Ereignisse können nicht gleichzeitig auftreten)
- weitere:
http://www2.hs-fulda.de/~grams/dnkfln.htm#_Bayes-Schätzung

Bayessche Formel – Anwendungen

- Statistik,
- Hypothesenwissen modellieren,
- Schlussfolgerungen (Schließen) aus unsicherem Wissen,
- Qualitätsmanagement,
- Entscheidungstheorie,
- Verkehrsverteilung-Vorhersage,
- ...

Was erwartet Dich in diesem Kapitel?

Wahrscheinlichkeiten

Bedingte Wahrscheinlichkeiten

Bayessche Formel

Bayessche Netze

Naïve Bayes ➡ extra Kapitel


Bayessche Netze

- ab Mitte der 70er Jahre Kritik, da Unsicherheitsmaße und Inferenzverfahren häufig rein intuitiv begründet waren (insbesondere in der Medizin).
- Einbeziehung graphischer Faktoren
- Klassen von Wahrscheinlichkeiten
- Der neue Ansatz wird als
 - Bayessche Netze (*Bayesian networks*) bzw.
 - zerlegbare graphenbasierte Modelle (*decomposable graphic models*) bzw.
 - Belief-Netze (belief networks)bezeichnet.


Ein **Bayessches Netz** ist ein gerichteter azyklischer Graph (DAG), dessen Knoten Variablen und dessen Kanten die Existenz direkter Abhängigkeiten zwischen Knoten denotieren. Die Stärke solcher Abhängigkeiten wird auf Basis **bedingter Wahrscheinlichkeiten** angegeben.

Bayessche Netze – Komponenten

- Knoten des Netzes: Zufallsvariablen.
- Intuitive Bedeutung einer Kante von Knoten A zu Knoten B:
A hat **direkten Einfluss** auf B.
- Jeder Knoten hat eine Tabelle mit bedingten Wahrscheinlichkeiten, die den Einfluss der Eltern (Vorgängerknoten) auf den Knoten darstellt.
- Graph ist zyklensfrei: gerichteter azyklischer Graph (DAG).
- Diskrete Zufallsvariablen mit einer endlichen Anzahl von Zuständen.



erlaubt



nicht erlaubt

Bayessche Netze – Berechnen

Was wird nun durch ein Bayessches Netz besser?

Bisher Multiplikationsregel:

$$\prod_{i=1}^n P(A_i | A_{i-1} \cap \dots \cap A_1)$$


- n Variablen, bei zweiwertigen Variablen (stark oder schwach, ja oder nein, ...) Ausrechnen von 2^n Wahrscheinlichkeiten für jede Belegung mit Hilfe der Multiplikationsformel.
- Aufgrund der statischen und bedingten Unabhängigkeiten kann die Produktkette verkürzt werden.
- Von einem Knoten V_i ausgehend, interessieren nur noch die Vorgängerknoten $Eltern(V_i)$.
- Die Formel vereinfacht sich:

$$\prod_{i=1}^n P(V_i | Eltern(V_i))$$

Bayessche Netze – Berechnen Beispiel

Beispiel:

- 5 Variablen A, B, C, D, E
- allgemeine Multiplikationsformel für eine konkrete Belegung a, b, c, d, e:
$$P(a,b,c,d,e) = P(e|a,b,c,d) * P(d|a,b,c) * P(c|a,b) * P(b|a) * P(a)$$
- Dank der modellierten Abhängigkeiten im Bayesschen Netz reduziert sich das auf:
$$P(a,b,c,d,e) = P(e|c) * P(d|b,c) * P(c|a) * P(b|a) * P(a)$$



Damit wird nun für alle verschiedenen Variablenbelegungen im Produktraum die Wahrscheinlichkeit ausgerechnet.

Sobald eine Variable auf einen Wert festgelegt wird, geht die Rechnerei erneut los (bspw. E: $P(e+=1)$, $P(e-=0)$), da sich dieses Zusatzwissen auf andere Variablen im Netz auswirkt.

Propagierung

Propagierung (Ausbreitung):

Beschleunigung der Wahrscheinlichkeitsberechnung für alle Knoten im Bayesschen Netz.

- betrachtet werden die Einflussfaktoren einer Variable V auf ihre Eltern und
- betrachtet werden die Einflussfaktoren einer Variable V auf ihre Kinder.
- Damit lassen sich die neuen Wahrscheinlichkeitswerte für die Eltern/Kinder berechnen,
- diese geben ihre Änderung dann entlang (noch nicht abgearbeiteter Kanten !!! (**d.h. es wird nicht zurück propagiert!**)) weiter an ihre Eltern/Kinder, bis das ganze Netz durchpropagiert ist.



Propagierung

Datenfluss:

- Jedem Knoten ist bekannt, welchen Einfluss er auf Elternknoten $\rightarrow$ bzw. auf seine Kinder $\rightarrow$ hat.
- Dieser Einfluss wird durch die bedingten Wahrscheinlichkeiten bestimmt und kann unterschiedlich groß sein

(z.B. das Vorliegen von Husten beeinflusst die Wahrscheinlichkeiten für Lungenkrebs, Tbc, Asthma, Lungenentzündung, Grippe, “hat sich verschluckt” in unterschiedlichem Maße).

Beispiel Datenfluss, wenn Wert für B bekannt wird:



Zusammenfassung Bayessche Netze

- Bayessche Netze sind eine Kombination von Graphentheorie und Wahrscheinlichkeitstheorie.
- Wissen wird als Ansammlung von Wahrscheinlichkeiten ausgedrückt.
- Bei Polytree exakte Inferenz in linearer Zeit möglich, ansonsten exponentielle Laufzeit.
- Anwendungen:
Entscheidungsfindung,
Wissensrepräsentation,
Wettervorhersagen,
Diagnosen, ...

Soft Computing – Wahrscheinlichkeit & Bayes – Lernziele

... Begriffe:

Wahrscheinlichkeit, bedingte Wahrscheinlichkeit, abhängige und unabhängige Ereignisse, Induktion und Deduktion, Bayessches Netz verstanden haben,

... Bayessche Formel anwenden können.