



Hochschule für Angewandte Wissenschaften Hamburg
Hamburg University of Applied Sciences

Computational Intelligence

Prof. Dr.-Ing. Sabine Schumann

Fakultät Informatik und Digitale Gesellschaft

Daten - Terminologie



Bilder: Freedigitalphotos.net: Renjith Krishnan, ID-10082483 und ID-10086282

A word cloud centered around the theme of 'Big Data'. The words are arranged in a circular pattern, with the largest words being 'BIG', 'DATA', 'INFORMATION', 'STORAGE', 'ANALYSIS', 'RESEARCH', 'LEARNING', 'WORLD', 'BASED', 'TIMES', 'INTERNET', 'SEARCH', 'PETABYTES', 'MANAGEMENT', 'TECHNOLOGIES', 'VOLUME', 'SETS', 'MILLION', 'SCIENCE', 'FUTURE', 'DEVELOPMENT', 'TECHNOLOGY', 'NEW', 'BILLION', 'PARALLEL', 'STATE', 'CRITIQUE', 'USE', 'TRAFFIC', 'CURRENTLY', 'WILL', 'WORLDWIDE', 'ONLINE', 'DAY', 'MANAGE', 'SYSTEMS', 'PROCESS', 'MAKING', 'INTEGRATION', 'GOVERNMENT', 'RESULTS', 'SOCIAL', 'YEARS', 'SAN', 'NAS', 'DRIVE', 'REPLICATION', 'HANDLE', 'SOURCES', 'CHALLENGES', 'LIMITS', 'ANNOUNCED', 'PAST', 'COMPLEX', 'HAND', 'CAPACITY', 'ONE', 'SECOND', 'NATIONAL', 'FLOW', 'INITIATIVE', 'ECONOMIC', 'VARIETY', 'PROJECT', 'ANNUAL', 'NOW', 'DISTRIBUTED', 'RELEVANT', 'PER', 'RECORDS', 'COST', 'FUNDING', 'INSIGHT', 'TOOLS', 'CENTER', 'PARADIGM', 'APPROACHES', 'PROCESSES', 'IMPLEMENTATION', 'BECOMES', 'PRIVATE', 'INTERNATIONAL', 'PRIVACY', 'ANALYTICS', 'SIMULATIONS', 'VISUALIZATION', 'EFFECTIVE', 'BUSINESS', 'FRAMEWORK', 'MASSIVE', 'USING', 'DEFINITION', 'BETWEEN', 'STATISTICS', 'DETERMINE', 'WELL', 'SET', 'DEPARTMENT', 'QUERIES', 'HIGH', 'USERS', 'AMOUNT', 'RATE', 'REAL', 'STRUCTURE', 'WORK', 'APPLICATIONS', 'INFRASTRUCTURE', 'TERMS', 'YEAR', 'SUCCESSFUL', 'NEEDED', 'USES', 'COMPARED', 'CAPABILITIES', 'SHARED', 'ARCHITECTURE', 'HUGE', 'LESS', 'EVERY', 'BASED', 'TIMES', 'WORLD', 'VARIABLES', 'LEARNING', 'RESEARCH', 'ANALYSIS'.

Idee dieses Kapitels

- Ein paar Begriffe klären.
- Ein paar Begriffe in Zusammenhang bringen.

Daten, Daten, Daten ...

Im Jahr 2012 (!!!):
2.800.000.000.000.000.000.000 Bytes

Zur Visualisierung wollen wir uns mal folgendes vorstellen:

- ein Byte entspricht einem Buchstaben und
- wir schreiben 1000 Buchstaben auf eine Seite Papier

Dann würde der Stapel Papier rund 2000 mal der Entfernung Erde – Sonne entsprechen.

Data never sleeps

Wieviele Daten werden jede Minute erzeugt?



„The real revolution is not in the machines that calculate data
but in data itself and how we use it!“

Aus:

Viktor Mayer-Schönberger, Kenneth Cukier:
„Big Data – A Revolution that will transform how we live, work and think“
Eamon Dolan / Houghton Mifflin Harcourt, 2013



Der Mythos ...

... Big Data ist ganz was Neues!



Eindeutiges: NJEIN!

Bildquelle: <http://absolutobsolet.blogspot.de/2012/04/raider-heit-jetzt-twix.html>

Big Data (1) ... die 3 bzw. 4 „V“

3 „V“ nach Gartner (2011) und Lanley (2001):

- **Velocity (Geschwindigkeit):**
Daten entstehen mit hoher Geschwindigkeit – im Sekundentakt oder schneller.
- **Volume (Umfang):**
Es entstehen große Datenmengen, von denen man nichts wegwerfen möchte.
- **Variety (Vielfalt):**
Daten entstehen in vielen Varianten –
für ein relationales Datenmodell schwierig bis unmöglich.

Das 4. „V“ nach Mills u.a. (2012):

- **Veracity (Zuverlässigkeit):**
Qualität und Zuverlässigkeit der erhaltenen Daten
aufgrund der Herkunft können Daten unvollständig, inkonsistent, mehrdeutig sein

Big Data (2) ... und was noch ... 5, 6, 7, ...Vs ?

- Variability (Variabilität),
- Validity (Gültigkeit),
- Vulnerability (Anfälligkeit),
- Volatility (Volatilität) (Statistik: Schwankung von Zeitreihen), ...

Big Data (3)

- Neu: Möglichkeit zur „intelligenten“ Verarbeitung beliebig schnell anwachsender, schnelllebig, beliebig großer und beliebig strukturierter Daten und Datenströme
- Neue Technologien und Algorithmen:
Interdisziplinäre Ursuppe der Fachgebiete Informationstechnik, Datenbanken, AI, Mathematik (insbesondere Statistik), Computerlinguistik, Interface-Design (HCI)
- Keine fertigen Technologie- und/oder Lösungsbaukästen
Für den speziellen Anwendungsfall muss eine spezifische Lösung aus einer Vielzahl von möglichen Systemen und Komponenten erstellt werden

Wie sieht die Rezeptur aus?



Bildquelle: <http://www.asterix.com/asterix-von-a-bis-z/die-charaktere/miraculix.html>

Rezept besteht aus ...

... Infrastruktur

Google, Amazon, Facebook etc. stießen an technische Grenzen bei ihrer Produkt-Entwicklung



Notwendigkeit neuer Technologien



Ziel: Hochskalierbar, Kosten/Daten = linear

- Cloud
- Hadoop
- ...

Rezept besteht aus ...

... Software-Entwicklung

- Parallel-Verarbeitung
- Map/Reduce
- NoSQL (Column Stores, inMemory Datenbanken)
- Realtime Stream Processing
- ...

Rezept besteht aus ...

... **ein wenig Magie** aus den Fachbereichen AI, Computerlinguistik und Mathematik:

- Maschinelles Lernen
- Neuronale Netze
- Wahrscheinlichkeiten, Bayessche Formel, Bayessche Netze
- Klassifikation
- Clustering
- Semantic Web
- Sprachverarbeitung
- ...

Rezept besteht aus ...

... Interfaces

- Datenvisualisierung
- Storytelling
- APIs
- HTML5, javascript
- REST, JSON
- ...

Wissensgewinnung – wo sind die Daten dazu?


Daten, die bislang betrachtet werden können

Daten „liegen“ bereits gespeichert irgendwo in der Firma herum.

- Blindes Analysieren, ob sich daraus neue Erkenntnisse gewinnen lassen (Bsp: andere Kunden, die dieses Produkt gekauft haben, haben auch ... gekauft)
- Hypothese aufstellen und dann gezielt nach dem Beweis suchen (Vorsicht ...)

Hypothese aufstellen (1)


Ist das ein Ausrutscher?



Idee und Bild: The unbelievable Machine Company, Berlin


Hypothese aufstellen (2)

... mehr Daten ... Und Hypothese bestätigt?



Hypothese aufstellen

Noch mehr Daten ...



Idee und Bild: The unbelievable Machine Company, Berlin

Wissensgewinnung – wo sind die Daten dazu?

- Daten, die bisher nicht betrachtet wurden
- Man hat ein Thema, das einen interessiert und man geht erst auf die Suche nach den Daten.
Bsp: Journalismus

Verteilte Datenbank


Normalerweise Client-Server-Umgebung, Speicherung der Daten auf einem zentralen Server

Verteilung

- Datenbestände, die **logisch zusammengehören**, werden „verteilt“
- Datenbestände können physisch an verschiedenen Speicherorten verteilt werden (Rechner, Platte, Tablespace, ...)
- Kommunikation über Netzwerk möglich
- Man unterscheidet
 - Horizontale Verteilung,
 - Vertikale Verteilung,
 - Replikation.


Relationales Datenbankschema am Beispiel Webshop – ERM

ERM:
Entity-Relationship-Model




Verteilte Datenbank – Webshop – Tabelle Bestellung – Horizontal

Horizontale Verteilung der Daten von Bestellung:




Verteilte Datenbank – Webshop – Tabellen Bestellung/besitzt – Vertikal

Vertikale Verteilung von Bestellung und besitzt:



Verteilte Datenbank – Webshop – Tabelle Bestellung – Replikation


(vollständige) Replikation der Daten von Bestellung:



Business Intelligence (BI) (1)

- Sammelbegriff für Techniken zur Konsolidierung, Analyse und Bereitstellung von Daten zur Entscheidungsunterstützung und Steigerung der Rentabilität eines Unternehmens.
- d.h. alle Informationssysteme, die modell- und methodenbasierend eine zielgerichtete Analyse vorhandenen Datenmaterials ermöglichen.
- grundlegende Voraussetzung ist die Existenz eines harmonisierten, aufbereiteten und abgestimmten Datenpools, auf den bspw. Data-Mining-Produkte und Werkzeuge zum Online Analytical Processing (OLAP) zugreifen.

Business Intelligence (BI) (2)



Bildquelle: Freedigitalphotos.net: Renjith Krishnan

Darstellung nach Laudon, Laudon, Schoder: Wirtschaftsinformatik, Pearson, 2010

Data Warehouses & Data Marts

Data Warehouse:


Datenbanksystem mit Berichts- und Abfragefunktionen, das operative und historische Daten speichert, die aus verschiedenen betrieblichen Systemen extrahiert wurden und für (Management-) Berichte und Analysen zusammenführt und aufbereitet.

Data Mart:

kleines Data Warehouse, in dem ein Teil der Unternehmensdaten für eine spezielle Funktion oder Gruppe von Nutzern aufbereitet und gespeichert wird.

Data Warehouses & Data Marts

Komponenten eines Data Warehouse




Darstellung nach Laudon, Laudon, Schoder: Wirtschaftsinformatik, Pearson, 2010

OLAP


Mehrdimensionale Datenanalyse - OLAP (OnLine Analytical Processing)

- Technik, um Daten nach mehreren Dimensionen bzw. aus mehreren Perspektiven zu analysieren
- Speicherung der Daten als Cube (Würfel)
- Einfacher und rascher Datenzugriff
- Gute Analysemöglichkeiten
- Zentraler Bestandteil aller modernen Reporting- und Analysesysteme der BI



Bildquelle: http://www.business-intelligence.org/wp-content/uploads/OLAP_Cube.jpg

Knowledge Discovery und Data Mining



Nach: Fayyad, Piatetsky-Shapiro, Smyth: The KDD Process for Exreacting Useful Knowledge from Volumes of Data Comm. ACM39 (1996), November, Nr. 11, <http://dx.doi.org/10.1145/240455.240464>

Data Analytics

Aus den gefundenen Mustern Schlussfolgerungen ziehen.

Bspw. :

Warenkorbanalyse-Problem „Wer Chips kauft, kauft auch häufig (85%) Cola“



- ➡ Cola und Chips räumlich nah beieinander platzieren
- ➡ Aktion: bei 3 Tüten Chips eine Cola gratis
etc. pp.

und noch ein Schlagwort: Predictive Analytics



Bildquelle: <http://www.computerwoche.de/a/was-ist-was-bei-predictive-analytics,3098583/>

Predictive Analytics


nach Gartner:

beschreibt **Predictive Analytics** jede Form von Data-Mining mit folgenden vier Eigenschaften:

1. Schwerpunkt auf einer **Vorhersage**, die getroffen wird (anstatt nur reine Beschreibung, Klassifikation, Clustering)
2. Durchführung **schneller** Analysen (in Stunden oder Tagen, anstatt der für Data-Mining üblichen Monate)
3. Betonung der **Business-Relevanz** der gewonnenen Einsichten (keine Elfenbeinturm-Analysen)
4. wichtig: **Einfachheit** der Benutzung, um die Tools für Business-Nutzer verfügbar zu machen.

nach Gartner: <http://www.gartner.com/it-glossary/predictive-analytics/>

Predictive Analytics



Darstellung nach Gartner: <http://www.gartner.com/it-glossary/predictive-analytics/>