



Hochschule für Angewandte Wissenschaften Hamburg  
*Hamburg University of Applied Sciences*

# Computational Intelligence

Prof. Dr.-Ing. Sabine Schumann

Fakultät Informatik und Digitale Gesellschaft

**KDD, CRISP & ASUM**

# Worum geht es?



Ist es möglich, die angefallenen und weiter anfallenden riesigen und ständig anwachsenden Datenbestände in nützliche Informationen oder sogar Wissen umzuwandeln?




Abbildung aus Wolfgang Ertel, Grundkurs KI, Springer 2013, S. 182

# Warenkorb-Analyse



# car2go und carpooling.com


Einsatzbereich der Autos (operating area) versus Stadtgrenze

## pro Tag pro Auto:

- durchschnittliche Nutzung in km
- durchschnittliche Nutzungszeit in Minuten
- durchschnittliche Anzahl der Nutzungen
- Nutzung nach Uhrzeit

## pro Woche pro Stadt:

- oft frequentierte Routen
- Wochentagsabhängigkeit
- Nutzung nach Uhrzeit
- Start- und Zielgebiete



Visualisierung von carpooling.com durch ubilabs

<http://vimeo.com/ubilabs/carpooling>




# Data Mining Cup



prudsys AG – Realtime Analytics Company

Chemnitz, Berlin, Almere (NL), Mailand (It), Istanbul (Tü)

- gegründet 1998 in Chemnitz u.a. von Andreas Ittner, Prof. Dr. Werner Dilger (1942-2007)
- Inhaber zahlreicher Patente
- Zusammenarbeit mit vielen wissenschaftlichen Instituten
- Organisator des Data Mining Cups (DMC)
  - weltweit größter Team-Wettbewerb für Intelligente Datenanalyse und -prognose,
  - seit 2000,
  - jährlich im Frühjahr,
  - für Studierende nationaler und internationaler Bildungseinrichtungen
  - (max. 2 Teams pro Einrichtung)



heise online 08.03.2017



Das Magazin Business Insider wusste im vorigen Herbst von einer ganz besonderen Dating-Agentur in den USA zu berichten. Nicht Algorithmen vermitteln dort Partner, sondern Menschen.  
Gründerin E. Jean Carroll erklärt: "Die Leute sind nicht immer ganz ehrlich, wenn sie sich online selbst beschreiben. Algorithmen funktionieren nicht. Ein Computer kann Menschen nicht zusammenbringen."



Die ZEIT kommentierte:  
"So weit ist es schon gekommen:  
Menschen nehmen Algorithmen wieder die Arbeitsplätze weg."



# Daten, Daten, Daten ... analysieren & verdienen

Haben Sie / hast Du etwas zu verbergen?

**Was verdient man mit den Daten über**

**Wer sucht ein Auto?**

**0,18 amerikanische Cent**

**Wer sucht nach einem Handy?**

**1,25 amerikanische Cent**


**Welche Frau ist schwanger?**

**11 amerikanische Cent**

**Wer hat Asthma, Diabetes, Übergewicht, Rückenprobleme, ...?**

**26 amerikanische Cent**

**Das scheint wenig ... aber bei 700 Millionen Profilen ...!**





# KDD – Knowledge Discovery in Databases



\*1958

Gregory Piatetsky-Shapiro, 1989:

**Knowledge Discovery in Databases (KDD)** (Wissensentdeckung in Datenbanken)

„Knowledge Discovery in databases (KDD) is the non-trivial process of identifying valid, novel, potentially useful, and ultimately understandable patterns in data.“

Fayyad, Usama M. ; Piatetsky-Shapiro, Gregory; Smyth, Padhraic:  
*From Data Mining to Knowledge Discovery in Databases.*  
AI Magazine, American Association for Artificial Intelligence, 1996




\*1963

„Data mining (DM) is a step in the KDD process ...“

Bildquelle: [https://commons.wikimedia.org/wiki/File:Gregory\\_Piatetsky-Shapiro\\_NYC\\_2016.jpg](https://commons.wikimedia.org/wiki/File:Gregory_Piatetsky-Shapiro_NYC_2016.jpg) MatthewP422, CC BY-SA 4.0  
[https://en.wikipedia.org/wiki/Usama\\_Fayyad#/media/File:Usama\\_Fayyad\\_pic.jpg](https://en.wikipedia.org/wiki/Usama_Fayyad#/media/File:Usama_Fayyad_pic.jpg) Graceofrox, CC BY-SA 3.0

# Schritte des KDD (1)



Darstellung nach rithme.eu und [Fayyad u.a. 1996] von Michelle Weck

# Schritte des KDD (2)

- Datenselektion / Datenextraktion  
Welche Daten sind notwendig und verfügbar? (auch Hintergrundwissen!, rechtliche Probleme ...)
- Datenbereinigung/-säuberung und –vorverarbeitung  
Fehlende Werte, Ausreißer, Inkonsistenzen, ...
- Datenreduktion (z. B. durch Transformation),  
Format für Data Mining (einzelne Tabelle), Aggregation, Aufteilung in Trainings- und Testdaten
- Datenanalyse durch **Data Mining**,  
Finden von Mustern
- Interpretation & Auswertung der Ergebnisse,  
Evaluation, Visualisierung, Präsentation, Einsatz


(im Normalfall werden diese Schritte mehrfach durchlaufen.)

Es gibt keinen fertigen Technologie- oder Lösungsansatz.

Aus einer Vielzahl von Systemen & Komponenten ist eine für den Anwendungsfall spezifische Lösung zu erstellen.

## ein weiteres Data-Mining-Prozess-Modell: CRISP

- **C**Ross **I**ndustry **S**tandard **P**rocess for **D**ata **M**ining (CRISP-DM)
- Ziel:  
Schritt-für-Schritt-Anleitung für das Data Mining bereitstellen
- EU-Projekt von 1996-1999
- wurde durch ein Konsortium von Firmen entwickelt



Bildquelle: [https://en.wikipedia.org/wiki/Cross\\_Industry\\_Standard\\_Process\\_for\\_Data\\_Mining](https://en.wikipedia.org/wiki/Cross_Industry_Standard_Process_for_Data_Mining)

# CRIPS-DM

1. Verstehen der Aufgabe (Business Understanding)
  - betriebliche Anforderungen verstehen und formulieren eines Lösungsmodells
2. Verständnis der Daten (Data Understanding)
  - Initiale Daten sammeln, beschreiben, untersuchen
  - Datenqualität prüfen
3. Datenvorbereitung (Data Preparation)
  - Auswahl der Daten, Datenbereinigung und Vorverarbeitung
4. Data Mining / Modellbildung (Modeling)
  - Anwenden verschiedener Mining-Techniken
  - Tests erstellen und durchführen
5. Evaluation
  - Erfolgskriterien auf Resultate anwenden
  - Prozess analysieren, Fehleranalyse
6. Einsatz und Konsequenzen für die Firma (Deployment)
  - Einsatz und Monitoring planen
  - Projekt analysieren


# KDD versus CRISP

- Phasen 1-2 und 6 von CRISP sind nicht im KDD zu finden
- Phase 3 von CRISP beinhaltet die ersten 3 Phasen des KDD



# ASUM-DM

- **A**nalytics **S**olutions **U**nified for **D**ata **M**ining
- IBM geschaffene Erweiterung von CRISP-DM
- Veröffentlicht 2015
- Die Analytics Solutions Unified Method for Data Mining/Predictive Analytics soll Schwachstellen von CRISP-DM beseitigen.  
Sie beinhaltet verbesserte Maßnahmen, Templates, Vorgaben und Maßnahmen.
- 2 Varianten:  
eine IBM interne und eine freie, im Internet erhältliche



Bildquelle: <ftp://ftp.software.ibm.com/software/data/sw-library/services/ASUM.pdf>

# Interpretation und Auswertung

Interessantheit der Erkenntnisse:

- **Gültigkeit**  
misst, wie zuverlässig ein entdecktes Muster auch für neue Daten Geltung besitzt.
- **Neuartigkeit**  
zeigt, wie ein gefundenes Muster bereits vorhandenes Wissen erweitert oder Widersprüche aufdeckt.
- **Nützlichkeit**  
misst den praktischen Nutzen für den Nutzer.
- **Verständlichkeit**  
erfasst, in wie weit die Bedeutung eines Musters vom Anwender nachvollzogen wird.

# Visualisierung




„Eine gute Visualisierung ist für den Erfolg eines Data-Mining-Projekts unerlässlich.“  
Jürgen Cleve, Uwe Lämmel: Data Mining, De Gruyter Oldenburg, 2020, S.235



„Visualization is critical to data analysis.  
It provides a front line of attack, revealing intricate structure in data that cannot be absorbed in any other way.  
We discover unimagined effects, and we challenge imagined ones.“  
William S. Cleveland: Visualizing Data, Hobart Press, 1993

# KDD versus Mining

- wird oft als Synonym füreinander verwendet, was aber **falsch** ist
- Mining ist der zentrale rechenintensive und automatisierbare Schritt im KDD-Prozess
- Anwendung von Algorithmen zur Aufdeckung von Strukturen und Mustern



- KDD-Prozess ist iterativ
- häufig sind Wiederholungen der vorhergehenden Phasen des Minings erforderlich, um gewünschte Ziele bzw. Ergebnisse zu erreichen
- Parameter der gewählten (Data) Mining-Technik sind anzupassen
- verwendeter Datenbestand ist neu zu bestimmen und vorzubereiten

# Ten (ethic) rules for responsible data research

Published: March 30, 2017 <https://doi.org/10.1371/journal.pcbi.1005399>

Matthew Zook, Solon Barocas, danah boyd, Kate Crawford, Emily Keller, Seeta Peña Gangadharan, Alyssa Goodman, Rachelle Hollander, Barbara A. Koenig, Jacob Metcalf, Arvind Narayanan, Alondra Nelson, Frank Pasquale

1. Acknowledge that data are people and can do harm
2. Recognize that privacy is more than a binary value
3. Guard against the reidentification of your data
4. Practice ethical data sharing
5. Consider the strengths and limitations of your data; big does not automatically mean better
6. Debate the tough, ethical choices
7. Develop a code of conduct for your organization, research community, or industry
8. Design your data and systems for auditability
9. Engage with the broader consequences of data and analysis practices
10. Know when to break these rules

<http://journals.plos.org/ploscompbiol/article?id=10.1371/journal.pcbi.1005399>