



Hochschule für Angewandte Wissenschaften Hamburg
Hamburg University of Applied Sciences


Computational Intelligence

Prof. Dr.-Ing. Sabine Schumann

Fakultät Informatik und Digitale Gesellschaft

KDD - Schritte

Schritte des KDD (1)



Darstellung nach rithme.eu und [Fayyad u.a. 1996] von Michelle Weck

Schritte des KDD (2)

- Datenselektion / Datenextraktion
Welche Daten sind notwendig und verfügbar? (auch Hintergrundwissen!, rechtliche Probleme ...)
- Datenbereinigung/-säuberung und –vorverarbeitung
Fehlende Werte, Ausreißer, Inkonsistenzen, ...
- Datenreduktion (z. B. durch Transformation),
Format für Data Mining (einzelne Tabelle), Aggregation, Aufteilung in Trainings- und Testdaten
- Datenanalyse durch **Data Mining**,
Finden von Mustern
- Interpretation & Auswertung der Ergebnisse,
Evaluation, Visualisierung, Präsentation, Einsatz




Genügend Daten?
Balancierte
Datenmenge?
...

(im Normalfall werden diese Schritte mehrfach durchlaufen.)

Es gibt keinen fertigen Technologie- oder Lösungsansatz.

Aus einer Vielzahl von Systemen & Komponenten ist eine für den Anwendungsfall spezifische Lösung zu erstellen.

Aufwandsverteilung bei KDD




Beispieldatensatz

Zielstellung:


Visuelle Gruppierung von Mitarbeitern einer Firma in Hamburg anhand personenbezogener Daten

PersNr	PLZ	Geschlecht	Alter	Jahresgehalt	Firmenzugehörigkeit	Position	Abschluss
1	20097	m	52	40	5	manager	Master
2	20097	m	28	27	6	arb	Lehre
3	20097	w	57	35000	25	verw	Bachelor
4	20097	m	45	32	10	arb	Lehre
5	20097	W	37	30	10	verw	Abi
6	20097	w	35	30	15	verw	Abi
7	20097	m	37		5		
8	20097	male	57	45	25	manager	Master
9	20097	m	45	32	8	arb	
10	20097	fem	26	27	96	arb	Lehre
11	20097	M	39	39	4	manager	Master
12	20097	m	42	31	15	arb	ohne
13	20097	m	38	32	3	arb	Lehre

Daten ... woher?



Selektion – Auswahl der Daten



Datenbanksysteme

- Relationale DBS: MySQL, PostgreSQL, Oracle, MS SQL Server, SQLite,
- Über JDBC
- NoSQL-DBS: MongoDB, ...

Files


- CSV, txt, Excel, Word, PDF
- XML, JSON, PMML (Predictive Model Markup Language)
- Bilder (png, jpg, jpeg, gif, ...)
- Videos (mp4, ...)

Andere Datenquellen

- Twitter, Google, Facebook, ...
- Sharepoint, ...
- ...

Welche Daten? Alle?

- geeignete Daten aus Datenquellen abrufen
Welche Daten sind notwendig, um die Aufgabe zu lösen?
- Beschränkung auf repräsentative Teilmenge des Datenbestandes
Viele Exemplare mit wenigen, aber aussagekräftigen Merkmalen




Beispiel für Datenselektion

PersNr	PLZ	Geschlecht	Alter	Jahresgehalt	Firmenzugehörigkeit	Position	Abschluss
1	20097	m	52	40	5	manager	Master
2	20097	m	28	27	6	arb	Lehre
3	20097	w	57	35000	25	verw	Bachelor
4	20097	m	45	32	10	arb	Lehre
5	20097	W	37	30	10	verw	Abi
6	20097	w	35	30	15	verw	Abi
7	20097	m	37		5		
8	20097	male	57	45	25	manager	Master
9	20097	m	45	32	8	arb	
10	20097	fem	26	27	96	arb	Lehre
11	20097	M	39	39	4	manager	Master
12	20097	m	42	31	15	arb	ohne
13	20097	m	38	32	3	arb	Lehre

uninteressant


Bereinigen




- Qualität der ausgewählten Daten?
- Fehler oder Inkonsistenzen (widersprüchliche Daten)
- Fehlende Werte
- Ausreißer

Einfluss der Datenauswahl auf die Interpretation


Ist das ein Ausrutscher?



Sieht so aus ...



... ups!



Idee und Bild: The unbelievable Machine Company, Berlin

Bereinigung unseres Beispiels (1)

PersNr	Geschlecht	Alter	Jahresgehalt	Firmenzugehörigkeit	Position	Abschluss
1	m	52	40	5	manager	Master
2	m	28	27	6	arb	Lehre
3	w	57	35000	25	verw	Bachelor
4	m	45	32	10	arb	Lehre
5	W	37	30	10	verw	Abi
6	w	35	30	15	verw	Abi
7	m	37		5		
8	male	57	45	25	manager	Master
9	m	45	32	8	arb	
10	fem	26	27	96	arb	Lehre
11	M	39	39	4	manager	Master
12	m	42	31	15	arb	ohne
13	m	38	32	3	arb	Lehre

Bereinigung unseres Beispiels (2)

PersNr	Geschlecht	Alter	Jahresgehalt	Firmenzugehörigkeit	Position	Abschluss
1	m	52	40	5	manager	Master
2	m	28	27	6	arb	Lehre
3	w	57	35000	25	verw	Bachelor
4	m	45	32	10	arb	Lehre
5	w	37	30	10	verw	Abi
6	w	35	30	15	verw	Abi
7	m	37		5		
8	m	57	45	25	manager	Master
9	m	45	32	8	arb	
10	w	26	27	96	arb	Lehre
11	m	39	39	4	manager	Master
12	m	42	31	15	arb	ohne
13	m	38	32	3	arb	Lehre

konsistent

Bereinigung unseres Beispiels (3)

PersNr	Geschlecht	Alter	Jahresgehalt	Firmenzugehörigkeit	Position	Abschluss
1	m	52	40	5	manager	Master
2	m	28	27	6	arb	Lehre
3	w	57	35	25	verw	Bachelor
4	m	45	32	10	arb	Lehre
5	w	37	30	10	verw	Abi
6	w	35	30	15	verw	Abi
7	m	37		5		
8	m	57	45	25	manager	Master
9	m	45	32	8	arb	
10	w	26	27	96	arb	Lehre
11	m	39	39	4	manager	Master
12	m	42	31	15	arb	ohne
13	m	38	32	3	arb	Lehre

konsistent

Bereinigung unseres Beispiels (4)

PersNr	Geschlecht	Alter	Jahresgehalt	Firmenzugehörigkeit	Position	Abschluss
1	m	52	40	5	manager	Master
2	m	28	27	6	arb	Lehre
3	w	57	35	25	verw	Bachelor
4	m	45	32	10	arb	Lehre
5	w	37	30	10	verw	Abi
6	w	35	30	15	verw	Abi
7	m	37		5		
8	m	57	45	25	manager	Master
9	m	45	32	8	arb	
10	w	26	27	96	arb	Lehre
11	m	39	39	4	manager	Master
12	m	42	31	15	arb	ohne
13	m	38	32	3	arb	Lehre


1996 (21 Jahre) oder 96 Monate (8 Jahre)?
Alter 26 ...

konsistent

Bereinigung unseres Beispiels (5)

PersNr	Geschlecht	Alter	Jahresgehalt	Firmenzugehörigkeit	Position	Abschluss
1	m	52	40	5	manager	Master
2	m	28	27	6	arb	Lehre
3	w	57	35	25	verw	Bachelor
4	m	45	32	10	arb	Lehre
5	w	37	30	10	verw	Abi
6	w	35	30	15	verw	Abi
7	m	37		5		
8	m	57	45	25	manager	Master
9	m	45	32	8	arb	
10	w	26	27	8	arb	Lehre
11	m	39	39	4	manager	Master
12	m	42	31	15	arb	ohne
13	m	38	32	3	arb	Lehre

Umgang mit fehlenden Daten

- Attribut komplett ignorieren
 - Datensatz komplett ignorieren
 - Fehlende Werte manuell einfügen (aufwendig bei vielen Daten)
 - Globale Konstante (bspw. <unbekannt> oder -1000)
 - Durchschnittswert des Attributs (ggf. nach Klasse)
 - Wahrscheinlichster Wert
 - Häufigster Wert
 - Wert nach Relation zu anderen Attributen (z.B. Alter $\leftrightarrow$ Geburtsjahr)
- 
- Notlösungen!


Bereinigung unseres Beispiels (6)

PersNr	Geschlecht	Alter	Jahresgehalt	Firmenzugehörigkeit	Position	Abschluss
1	m	52	40	5	manager	Master
2	m	28	27	6	arb	Lehre
3	w	57	35	25	verw	Bachelor
4	m	45	32	10	arb	Lehre
5	w	37	30	10	verw	Abi
6	w	35	30	15	verw	Abi
7	m	37	45	5	manager	Master
8	m	57	45	25	manager	Master
9	m	45	32	8	arb	Lehre
10	w	26	27	8	arb	Lehre
11	m	39	39	4	manager	Master
12	m	42	31	15	arb	ohne
13	m	38	32	3	arb	Lehre



häufigster Wert, der bei Position arb vorkommt.

Bereinigen mit KNIME (1)

Mit dem Data Explorer Node kann man sich zu jedem Attribut die Daten (grafisch) anzeigen lassen.




Numerische Ausreißer entdecken und behandeln.



Bereinigen mit KNIME (2)

Textfelder manuell behandeln:


- Werte zählen in einer Spalte
- RowID ermitteln für gleiche Werte
- Row Splitten in Rows mit und ohne Fehler (nach Anzahl)
- Neue Spalte hinzufügen
- Korrekte Werte manuell in einem JavaScript Fenster eingeben
- Datensätze wieder zusammenbringen
- Unnötige Spalte(n) entfernen



Bereinigen mit KNIME (3)

Textfelder anhand von Ähnlichkeiten „automatisch“ behandeln:

- Werte zählen in einer Spalte
- RowID ermitteln für gleiche Werte
- Row Splitten in Rows mit und ohne Fehler (nach Anzahl)
- Jeder Wert bekommt eine eigene ID
- Ähnlichkeitssuche: in den unteren Port gehen die Daten einer Referenztabelle ein. Spalten müssen in Ausgangs- und Referenztabelle gleich heißen.
- Daten wieder zusammenführen
- Unnötige Spalte(n) wieder löschen




Bereinigen mit KNIME

Fehlende Werte finden und behandeln

- Fehlende Werte detektieren, Spalten ermitteln
- Regeln aufstellen, wie mit leeren Feldern in einer konkreten Spalte umgegangen werden soll
Bspw. falls das Geburtsdatum vorhanden ist, ermittle das Alter




Transformieren



- Umwandeln der Daten in eine Form, die vom Mining-Verfahren verarbeitet werden kann (Bspw. Text kodieren)
- Reduktion korrelierender Attribute
- Normalisierung von Werten (bspw. Normalisierung im Intervall $[0,1]$)

Datentransformation in unserem Beispiel (1)

enthält offensichtlich keine Information!



PersNr	Geschlecht	Alter	Jahresgehalt	Firmenzugehörigkeit	Position	Abschluss
1	m	52	40	5	manager	Master
2	m	28	27	6	arb	Lehre
3	w	57	35	25	verw	Bachelor
4	m	45	32	10	arb	Lehre
5	w	37	30	10	verw	Abi
6	w	35	30	15	verw	Abi
8	m	57	45	25	manager	Master
9	m	45	32	8	arb	Lehre
10	w	26	27	8	arb	Lehre
11	m	39	39	4	manager	Master
12	m	42	31	15	arb	ohne
13	m	38	32	3	arb	Lehre

Datentransformation in unserem Beispiel (2)

Ziel ist Clustern – beim Clustern sind metrische Werte günstig



Geschlecht	Alter	Jahresgehalt	Firmenzugehörigkeit	Position	Abschluss
m	52	40	5	manager	Master
m	28	27	6	arb	Lehre
w	57	35	25	verw	Bachelor
m	45	32	10	arb	Lehre
w	37	30	10	verw	Abi
w	35	30	15	verw	Abi
m	57	45	25	manager	Master
m	45	32	8	arb	Lehre
w	26	27	8	arb	Lehre
m	39	39	4	manager	Master
m	42	31	15	arb	ohne
m	38	32	3	arb	Lehre

Datentransformation in unserem Beispiel (3)

m:0 w:1

arb:0 verw:1 manager:2


ohne:0 Lehre:1 Abi:2 Bachelor:3 Master:4



Geschlecht	Alter	Jahresgehalt	Firmenzugehörigkeit	Position	Abschluss
0	52	40	5	2	4
0	28	27	6	0	1
1	57	35	25	1	3
0	45	32	10	0	1
1	37	30	10	1	2
1	35	30	15	1	2
0	57	45	25	2	4
0	45	32	8	0	1
1	26	27	8	0	1
0	39	39	4	2	4
0	42	31	15	0	0
0	38	32	3	0	1

Normalisieren von Daten

Ziel: Werte im Intervall $[0,1]$



Normalisierung:

$$x_j^{(i)} \text{ norm} = \frac{x_j^{(i)} - \min(x_j)}{\max(x_j) - \min(x_j)}$$

Datentransformation in unserem Beispiel (4a)

$$x_2^{(1)} = \frac{52 - 26}{57 - 26} = \frac{26}{31} = 0,84$$


$$x_j^{(i)} \text{ norm} = \frac{x_j^{(i)} - \min(x_j)}{\max(x_j) - \min(x_j)}$$

Geschlecht	Alter	Jahresgehalt	Firmenzugehörigkeit	Position	Abschluss
0	52	40	5	2	4
0	28	27	6	0	1
1	57	35	25	1	3
0	45	32	10	0	1
1	37	30	10	1	2
1	35	30	15	1	2
0	57	45	25	2	4
0	45	32	8	0	1
1	26	27	8	0	1
0	39	39	4	2	4
0	42	31	15	0	0
0	38	32	3	0	1

Datentransformation in unserem Beispiel (4b)

für alle Spalten außer Geschlecht nötig

$$x_j^{(i)} \text{ norm} = \frac{x_j^{(i)} - \min(x_j)}{\max(x_j) - \min(x_j)}$$




Geschlecht	Alter	Jahresgehalt	Firmenzugehörigkeit	Position	Abschluss
0	0,84	40	5	2	4
0	0,06	27	6	0	1
1	1	35	25	1	3
0	0,61	32	10	0	1
1	0,37	30	10	1	2
1	0,29	30	15	1	2
0	1	45	25	2	4
0	0,61	32	8	0	1
1	0	27	8	0	1
0	0,42	39	4	2	4
0	0,52	31	15	0	0
0	0,39	32	3	0	1

Datentransformation in unserem Beispiel (4c)

$$x_j^{(i)} \text{ norm} = \frac{x_j^{(i)} - \min(x_j)}{\max(x_j) - \min(x_j)}$$


Geschlecht	Alter	Jahresgehalt	Firmenzugehörigkeit	Position	Abschluss
0	0,84	0,72	0,09	1	1
0	0,06	0	0,14	0	0,25
1	1	0,44	1	0,5	0,75
0	0,61	0,28	0,32	0	0,25
1	0,35	0,17	0,32	0,5	0,5
1	0,29	0,17	0,55	0,5	0,5
0	1	1	1	1	1
0	0,61	0,28	0,23	0	0,25
1	0	0	0,23	0	0,25
0	0,42	0,67	0,05	1	1
0	0,52	0,22	0,55	0	0
0	0,39	0,28	0	0	0,25

Data Mining




Das Thema hat ein eigenes Kapitel.

Evaluation & Interpretation (1)




- die entdeckten Muster und Beziehungen bewerten und interpretieren
- korrekte Interpretation von Data-Mining-Ergebnissen erfordert ein hohes Maß an Domänenkenntnissen
- Die Interpretation dient dazu, das Domänenwissen des Anwenders effektiv zu verändern, sie ist Voraussetzung für die Umsetzung der gewonnenen Erkenntnisse im Rahmen konkreter Handlungsmaßnahmen.
- Im Idealfall ein Team von Experten aus unterschiedlichen Bereichen, um sicherzustellen, dass die Bewertung korrekt ist und die gewonnenen Informationen bestmöglich genutzt werden.
- Bewertung von Mustern kann anhand des Kriteriums der **Interessantheit** erfolgen, folgende Dimensionen der Interessantheit sind sinnvoll:
 - Validität eines Musters
objektives Maß, mit welcher Sicherheit das gefundene Modell (beispielsweise ein Muster oder eine Assoziationsregel) auch in Bezug auf neue Daten gültig ist.
 - Neuartigkeit
erfasst, inwieweit ein Muster das bisherige Wissen ergänzt oder im Widerspruch zu diesem steht.
 - Verständlichkeit
misst, wie gut eine Aussage von einem Anwender verstanden werden kann.
 - Nützlichkeit eines Musters
erfasst den praktischen Nutzen für den Anwender.

Evaluation & Interpretation (2)



- nicht alle der aufgedeckten Muster erfüllen diese Kriterien
- Analyseverfahren fördern häufig viele Regelmäßigkeiten zutage aus denen dem Unternehmen kein Nutzen erwächst, die
 - irrelevant,
 - trivial,
 - bedeutungslos oder
 - bereits bekannt waren,
 - die unverständlich bzw. nicht nachvollziehbar sind.
- Typischerweise erfolgt Rücksprung in eine der vorherigen Phasen:
 - Anpassung der Parameter,
 - Auswahl einer anderen Data-Mining-Technik
 - andere Datenquellen heranziehen


Evaluation



- Plots
- Confusion Matrix und ganz viel Statistik
- ...

Plot

Beispiel: 2dimensionale Abbildung von Reuters-Kategorien



Bildquelle: http://lvdmaaten.github.io/tsne/examples/reuters_tsne.jpg

Confusion Matrix


		Tatsächliche Klasse	
		Positive	Negative
Vorhergesagte Klasse	Positive	True Positives (TPs)	False Positives (FPs)
	Negative	False Negatives (FNs)	True Negatives (TNs)

Confusion Matrix – Statistische Messgrößen

- True Positives Rate $TPR = \frac{TP}{TP+FN}$ (sensitivity, recall, hit rate)
- True Negatives Rate $TNR = \frac{TN}{TN+FP}$ (specificity, selectivity)
- False Negative Rate $FNR = \frac{FN}{FN+TP}$ (miss rate)
- False Positive Rate $FPR = \frac{FP}{FP+TN}$ (fall-out)
- Positive Predictive Value $PPV = \frac{TP}{TP+FP}$ (precision)
- Negative Predictive Value $NPV = \frac{TN}{TN+FN}$
- Accuracy $ACC = \frac{TP+TN}{TP+TN+FP+FN}$
- Balanced Accuracy $BA = \frac{TPR+TNR}{2}$
- F1 Score $F1 = \frac{2TP}{2TP+FP+FN}$ (harmonisches Mittel zwischen PPV und TPR)
- Matthews Correlation Coefficient $MCC = \frac{TP * TN - FP * FN}{\sqrt{(TP+FP) * (TP+FN) * (TN+FP) * (TN+FN)}}$

True Positives (TPs)	False Positives (FPs)
False Negatives (FNs)	True Negatives (TNs)

Veranschaulichung ACC, F1-Score & MCC



Grafikidee: Tobias Braun, Niklas Klupiec

und noch mehr Statistik

- False Discovery Rate
- False Omission Rate
- Prevalence Threshold
- Threat Score
- Fowlkes-Mallows index
- Bookmaker informedness
- Markedness

$$FDR = \frac{FP}{FP+TP}$$

$$FOR = \frac{FN}{FN+TN}$$

$$PT = \frac{\sqrt{TPR * (-TNR+1)} + TNR - 1}{TPR + TNR - 1}$$

$$TS = \frac{TP}{TP+FN+FP}$$

$$FM = \sqrt{PPV * TPR}$$

$$BM = TPR + TNR - 1 \quad (\text{informedness})$$

$$MK = PPV + NPV - 1 \quad (\text{deltaP})$$

True Positives (TPs)	False Positives (FPs)
False Negatives (FNs)	True Negatives (TNs)

(critical success index CSI)

