



Hochschule für Angewandte Wissenschaften Hamburg
Hamburg University of Applied Sciences

Computational Intelligence

Prof. Dr.-Ing. Sabine Schumann

Fakultät Informatik und Digitale Gesellschaft

Data Mining – Grundlagen

Was erwartet Dich in diesem Kapitel?

Grundbegriffe

Tools

... Daten ... woher?

Datentypen

Abstands- und Ähnlichkeitsmaße

ML  extra Kapitel

Anwendungsklassen  extra Kapitel

KNN  extra Kapitel

Auf Grundlage unserer bisherigen Erfahrungen, Annahmen, Gefühlen, Ideen, Heuristiken und dem „gesunden“ Menschenverstand, aber auch Vorurteilen versuchen wir tagtäglich etwas vorherzusagen.

- wie lange brauche ich, die Folien zu diesem Kapitel zu erstellen,
- welche Fußballmannschaften steigen in dieser Saison auf,
- in welche Aktie(n) investiere ich,
- ...

Unsere Annahmen sind aber nicht unbedingt wahr. Sie sind abhängig von äußeren Einflüssen, uns unbekannten Faktoren, unserer verzerrten Wahrnehmung der Realität, unserem Gedächtnis, unseren kognitiven Fähigkeiten, ...

Geht das besser?



Bildquelle: Screenshot „Harry Potter und der Gefangene von Askaban“, 2004

Data Mining ...


... ist kein neues Gebiet.

Bereits 1854 wurde eine erfolgreiche Analyse von Daten dokumentiert.

London hatte zu dieser Zeit eine Cholera-Epidemie.

Der Arzt Dr. John Snow entdeckte durch die Bildung von Clustern eine Häufung der Todesfälle in einem bestimmten Bereich, der durch eine Wasserpumpe in der Broad Street versorgt wurde.

Nachdem er durchsetzen konnte, dass diese Wasserpumpe stillgelegt wurde (der Schwengel wurde entfernt), nahmen in diesem Stadtteil die Todesfälle rapide ab.



1813 - 1858

Bildquelle: en.wikipedia.org

Daten & Information & Wissen

Daten

Unter diesem Begriff wird eine Ansammlung von Zeichen/Signalen/Symbolen mit dazugehöriger Syntax verstanden.

Information

Ein Datum wird zu einer Information, wenn es eine Bedeutung hat.

Wissen

(Eine) Information in Zusammenhang mit der Fähigkeit, diese zu benutzen.

Data Mining


Mit diesem Begriff wird die Extraktion von Wissen aus Daten bezeichnet.

Ausgangsfrage

Ist es möglich bisher angefallene und zukünftig anfallende Datenbestände in nützliche Informationen oder sogar Wissen umzuwandeln?

Wissen ...

- Besitz von objektiv bzw. subjektiv als wahr zu klassifizierenden Erfahrungen, die die Grundlage von Urteilen bilden können.
- (individuelles) Wissen – ist die Menge der individuellen Kenntnisse.
(Sachkenntnisse, Verfahrenkenntnisse, Normen-, Wertkenntnisse)
- Wissen in der Informatik:
ist Information, die man zu nutzen weiß



- Wissen in der Künstlichen Intelligenz
ist die symbolische Repräsentation der Welt, die das Denken bzw. Handeln von Agenten bestimmt

Wissen, heißt wissen, wo es gespeichert ist.

Explizites und implizites Wissen

Explizit

- Logische Aussagen
- Wenn-Dann-Regeln
- Semantische Netze
- Frames



direkt für die Wissensverarbeitung geeignet

Implizit

- Durch Wissensverarbeitung extrahierbares Wissen
- Datenmengen
- Programme / Algorithmen
- Neuronale Netze



ab- / herleitbares Wissen

Techniken zur Wissensgewinnung

- Knowledge Engineering (Interviews, ...)
- Data Mining
- Maschinelles Lernen
- ...




Gesichts- / Emotionserkennung

- TV-Serie „Lie to me“ basierend auf Arbeiten von Paul Ekman
- Fraunhofer Institut:
SHORE erkennt Geschlecht, Alter und Stimmung des Probanden



- Google Glass:
2014: NYPD testet Google Glass zur
Verbrechensbekämpfung



<http://nypost.com/2014/02/06/nypd-testing-google-glass-as-potential-crime-fighting-tool/>
<http://venturebeat.com/2014/02/05/nypd-google-glass/>

- Emotion Bike
HAW Hamburg: www.emotionbike.org



Bildquellen:

EmoBike: <https://pbs.twimg.com/media/CeJVI30XEAAm4O.jpg>

Google Glass: Image Credit: Jolie O'Dell/VentureBeat

www.iis.fraunhofer.de/shore

Data Mining


- Analyse großer Datenbestände, um Zusammenhänge, Muster und Regeln zu finden, die als Orientierungshilfe bei Entscheidungsfindung und Vorhersage zukünftiger Entwicklungen dienen können.
- Einsatz verschiedener Techniken, um **verborgende** Muster und Beziehungen in großen Datenbeständen zu erkennen.

Wir wollen implizites (nützliches) Wissen erhalten!

- Bestimmung der Anwendungsklasse, um ein geeignetes Verfahren zu ermitteln.

Wir wollen das weitestgehend automatisieren!

Maschinelles Lernen, Data Mining, KDD




- Maschinelles Lernen:
Ein „künstliches System“ lernt anhand von vorliegenden Beispielen und entwickelt Muster und Gesetzmäßigkeiten aus diesen Daten.
- Data Mining benutzt Maschinelles Lernen, allerdings geht es nun mehr um das Finden von neuen Mustern und Gesetzmäßigkeiten.
- Data Mining ist Bestandteil des Knowledge Discovery in Databases (KDD) Prozesses (Wissensentdeckung).

Data Mining – Anwendungsbeispiele

Beispielanwendungen:

- Beurteilung Kreditwürdigkeit
- Warenkorbanalyse
- Nach Kauf eines Hauses wird in 65% der Fälle nach 2 Wochen ein neuer Kühlschrank gekauft und in 45% der Fälle innerhalb von 4 Wochen ein Herd
- Stauwahrscheinlichkeit in der Ferienzeit, Verkauf von Fahrradzubehör auf der Basis des Fahrradverkaufs im letzten Quartal
- ...



Darstellung nach rithme.eu und [Fayyad u.a. 1996]

Schritte des KDD

- Datenselektion / Datenextraktion
Welche Daten sind notwendig und verfügbar? (auch Hintergrundwissen!, rechtliche Probleme ...)
- Datenbereinigung und –vorverarbeitung
Fehlende Werte, Ausreißer, Inkonsistenzen, ...
- Datenreduktion (z. B. durch Transformation),
Format für Data Mining (einzelne Tabelle), Aggregation, Aufteilung in Trainings- und Testdaten
- Datenanalyse durch **Data Mining**,
Finden von Mustern
- Interpretation & Auswertung der Ergebnisse,
Evaluation, Visualisierung, Präsentation, Einsatz

(im Normalfall werden diese Schritte mehrfach durchlaufen.)

Es gibt keinen fertigen Technologie- oder Lösungsansatz.

Aus einer Vielzahl von Systemen & Komponenten ist eine für den Anwendungsfall spezifische Lösung zu erstellen.

Weitere ähnliche Buzzwords

Analysis, Big Data, Biostatistics, Business Analytics, Business Intelligence, Data Archaeology, Datability, Data-Driven Decision Making, Data Forensic, Data Pattern Processing, Data Science, Econometrics, Knowledge Extraction, Information Discovery, Information Harvesting, Machine Learning, Signal Processing, Predictive Analytics, Statistical process control, Time Series, ...

(Danke an Ingo Boersch!)

Gemeinsamkeiten

Fragestellung, Prinzipien, Vorgehensweise, Techniken

immer interdisziplinär

Datenbanken, Statistik, Mustererkennung, ...


Informatik

ist immer dabei



Data Mining: Finden von Mustern

Ein Prozess erzeugt Daten (egal ob Unternehmen, Mensch, Maschine, ...)

Data Mining findet, konstruiert und optimiert
Modelle und Wissensrepräsentationen
zur Beschreibung und Vorhersage des Prozesses.



Verstehen



Be- und Ausnutzen

DM ist eine Querschnittstechnologie – Bsp. aus dem Labor für KI THB


• Wie erkennt man an der Dicke der Retina Multiple Sklerose? • Wovon hängt es ab, ob eine Student*in in der Veranstaltung „viel gelernt“ hat? • Welche Lehrstelle passt zu einer Bewerber*in?	Beschreiben
• Relevante Merkmale für einen hohen Wirkungsgrad bei Solarzellen • Wovon hängt beruflicher Erfolg nach dem Studium ab? • Suche nach Abhängigkeiten in astrophysikalischen Daten • Relevante Merkmale für den Stromverbrauch einer Nachtspeicherheizung • Wodurch unterscheiden sich leitliniengerecht behandelte Patient*innen von anderen?	Vorhersagen
• Wie viel Strom wird die Stadt Hamburg morgen um 12 Uhr verbrauchen? • Wie oft wird ein Buch in verschiedenen Buchläden verkauft werden? • Prognose, ob ein bestellter Artikel zurückgeschickt wird • Gruppieren interessanter Punkte wie Restaurants, Tankstellen, Sehenswürdigkeiten etc.	Beschreiben
	Vorhersagen
• Vorhersage, ob eine Webshop-Besucher*in den Warenkorb kauft oder nicht • Prognose der tatsächlichen Teilnehmer*innenzahl bei Nachprüfungen. • Musikempfehlung anhand von last.fm-Profilen • Prognose der Güte eines Schweißpunktes beim Punktschweißen • Woran ist eine Kaffeepflanze aus der Luft zu erkennen? • Sturzdetektion in einem NahInfraRotKamera-Video	Beschreiben
	Vorhersagen

Darstellung nach Ingo Boersch

Data Mining

- Text Mining
unstrukturierte Daten
Analyse von Textdokumenten

- Web Mining
semistrukturierte Daten



- Data Mining (im engeren Sinne)
meist **strukturierte** Daten

Zeichnung: nach Cleve, Lämmel: Data Mining, S. 71

Was erwartet Dich in diesem Kapitel?

Grundbegriffe

Tools

... Daten ... woher?

Datentypen

Abstands- und Ähnlichkeitsmaße

[illegible]

Kostenfreie Tools (1)

Bei den meisten Herstellern gibt es 2 Versionen eine kostenfreie und eine kommerzielle sogenannte duale Lizenzen: GPL + kommerzielle mit Service und Erweiterungen

Programmiersprachen:

- **R** GPL, Programmiersprache
- **Python** GPL, Programmiersprache



Kostenfreie Tools (2)

Bei den meisten Herstellern gibt es 2 Versionen eine kostenfreie und eine kommerzielle sogenannte duale Lizenzen: GPL + kommerzielle mit Service und Erweiterungen

- **Tensorflow**



- **KNIME** GPL + dual, Uni. Konstanz + KNIME.com GmbH (Zürich)



- **RapidMiner** Open + Closed Source, Uni. Dortmund + RapidMiner GmbH



- **WEKA** GPL, Universität von Waikato (Neuseeland)



- Orange GPL + Qt, University of Ljubljana (Slowenien)



- Rattle in R, Open Source, Fa. Togaware (Australien)


- H2O.ai (USA)



Kommerzielle Tools (1)

Gartner magic quadrant business intelligence

02/2021



06/2024



Kommerzielle Tools (2)

- IBM SPSS Modeller (USA)
- SAS (USA)
- Tableau (USA)
- Qlik (Schweden / USA)



Und in der Datenbank selber?

- Oracle Data Mining (ODM) (USA) Oracle Data Miner + Advanced Analytics Database Option
- SAP HANA
- MS SQLServer
- TERADATA
- NETEZZA
- ASTER
- PARACCEL
- Greenplum



Top Analytics, Data Science, Machine Learning Software 2017-2019, KDnuggets Poll




Fig 1: KDnuggets Analytics/Data Science 2019 Software Poll: top tools in 2019, and their share in the 2017, 2018 polls

<https://www.kdnuggets.com/2019/05/poll-top-data-science-machine-learning-platforms.html>

Was erwartet Dich in diesem Kapitel?

Grundbegriffe

Tools

... Daten ... woher?

Datentypen

Abstands- und Ähnlichkeitsmaße

Datasets (1)

- Kaggle (<https://www.kaggle.com>)
- Google Dataset Search (<https://datasetsearch.research.google.com>)
- Chars74K
- ImageNET (<http://www.image-net.org>)
- ImageClef (<http://www.imageclef.org/datasets>)
- VGG (University of Oxford)
- VoxCeleb2 (University of Oxford) (<http://www.robots.ox.ac.uk/~vgg/data/voxceleb/vox2.html>)
- YFCC100M (mit Anmeldung: Bild- und Videodaten)
- YouTube-8M (Videos, über semantisches Netz verknüpft)
- MS-Celeb-1M (Promibilder – eingeschränkte Nutzung!!!)
- CelebA (Promibilder)
- MS Coco

Datasets (2)

- MNIST und Fashion-MNIST (Modified National Institute of Standards and Technology) (handgeschriebene Zahlen)
- UCI-Datasets (<https://archive.ics.uci.edu/ml/datasets.php>) (University of California Irvine)
- ~~UBER-Datasets (<https://movement.uber.com>)~~
- CLEVR-Datasets (Compositional language and Elementary Visual Reasoning) (Stanford University) (<https://cs.stanford.edu/people/jcjohns/clevr>)
- WordNet (<https://wordnet.princeton.edu>)
- Überblick OpenData in Deutschland: Govdata (<https://www.govdata.de>)
- Bund, Länder, Kommunen in Deutschland: Statista (<https://de.statista.com>)
- Affectnet
- Affectiva
- ...

Checkliste zu Datensets

- Sind die Daten noch aktuell?
- Herausgeber vertrauenswürdig?
- Verfügbarkeit (online, offline, auf Anfrage)?
- Lizenzmodell?
- Nutzungsbedingungen (nicht- und /oder kommerziell)?
- Notwendigkeit von Copyright oder Zitat, Verweis auf Publikation?
- In welchem Format liegen die Daten vor (CSV, JSON, Excel, MATLAB, ...)?
- Medientypen (RGB-Bilder, Texte, Audio, ...)?
- Reicht das Volumen der Daten aus?
- Sind die Daten balanciert?
- Sind die Daten annotiert – wie steht es um die Granularität der Annotation?

Was erwartet Dich in diesem Kapitel?

Grundbegriffe

Tools

... Daten ... woher?

Datentypen

Abstands- und Ähnlichkeitsmaße

Informationen über Daten

Was wir bisher wissen:

Daten können strukturiert, semistrukturiert und/oder unstrukturiert vorliegen

Was sind das für Daten?

- Zahlen (1, 42, ...)
Rechnen, Vergleichen und Sortieren möglich
- Kategorien (klein, mittelgroß, groß, kalt, warm, heiß, jung, alt, ...)
Vergleichen und Sortieren möglich
- Nominale Daten (Farbe, Geschlecht, Augenfarbe, ...)

Kategorisierung von Datentypen anhand Rechnen & Ordnen

Nominal

- keine Rang- bzw. Reihenfolge

Ordinale

- es gibt eine Ordnungsrelation bspw. $<$

Metrische

- alle Ordnungsmerkmale reeller Zahlen
- mit diesen Daten kann gerechnet werden (Addition, Subtraktion)

Weitere Unterteilung:

Diskret

Endliche Anzahl von Werten
bspw. Noten:
0.7, 1.0, 1.3,
1.7, ...

Kontinuierlich

Numerische Daten, die innerhalb eines Definitionsbereiches jeden Wert annehmen können

Kontinuierliche Daten ...

- sind letztendlich aus Computersicht diskret, da eine exakte Darstellung durch die Begrenzungen des Rechners nicht möglich ist
- können in diskrete umgewandelt werden (*diskretisierte* Daten)
- numerische Daten müssen nicht zwingend kontinuierlich bzw. metrisch sein

Aus diesem Grund gibt es für numerische Daten auch skalenbasierte Unterscheidungskriterien.

- intervallbasiert
Jahreszahlen (gregorianischer K. , julianischer K. , Unix-Welt-K., Temperatur (Celsius, Fahrenheit), ...)
- verhältnisbasiert
natürlicher Nullpunkt, Verhältnisskala abhängig von Maßeinheit (Entfernung ... km, mm)
- absoluteskalenbasiert
hängen von keiner Maßeinheit ab
bspw. Lebensjahre, Anzahl der Eheschließungen, ...

Ordinal → Metrisch ?

Beispiel Temperatur

Mit kalt, lauwarm, warm, heiß

- Kalt → 0
- Lauwarm → 0.3
- Warm → 0.7
- Heiß → 1

Nominal → Metrisch?

Binärattribute bspw. Schalter mit an und aus

- an → 0
- aus → 1

Binärcodierung bspw. Geschlecht mit weiblich, männlich, divers

- Idee: Attribut vermehren

	Attribut _i	Geschlecht_w	Geschlecht_m	Geschlecht_d	Attribut _k
Datensatz1	...	1	0	0	...
Datensatz2	...	0	0	1	...
Datensatz3	...	1	0	0	...
Datensatz4	...	0	1	0	...
...	...	...	...	...	...

Metrisch → Ordinal?

Am Beispiel Körpergröße (cm) Erwachsener:

- 60-120 → sehr klein
- 121-160 → klein
- 161-180 → mittelgroß
- 181-190 → groß
- 191-275 → sehr groß

Bild: AFP



Zusammenfassender Überblick

Kategorie	Nominal	Ordinal	Metrisch
Charakteristik	• feststellbar, ob der Wert gleich oder verschieden ist • keine Richtung (kein besser, schlechter) und kein Abstand • Feature mit nur zwei Werten nennt man <i>dichotom</i>	• es existiert eine Ordnungsrelation (besser/schlechter) zwischen den Kategorien • aber es gibt keinen einheitlichen Abstand	• Sowohl Differenzen als auch Verhältnisse zwischen den Werten sind aussagekräftig • Werte können diskret oder stetig sein
Beispiele	Dichotom: • gesund / krank • enthält (keinen) Alkohol Nicht dichotom • Geschlecht • Augenfarbe	• Prüfungsnote (metrisch?) • Altersklasse • Güteklasse	• Körpergröße • Gewicht • Alter (stetig oder diskret) • Verkaufszahl (diskret)


Features (Merkmale) – Feature Vector

- Betrachtete Objekte sind komplex
- Geeignete Merkmale (Features) müssen gefunden werden, die für die Unterscheidung der Objekte (Klasse, Ähnlichkeit, ...) relevant ist

Beispiel:

Mögliche Features: a, b, c, d, e

- Features werden zu einem Feature Vector zusammengefasst.
- Der Merkmalsraum (Feature Space) ist meist hochdimensional (hier 5).




Erstellen von Feature Vector

Ursprungsobjekt



Dokument






Bild



Video

KI-Modell



Feature Vector

3 1 2 5 6 3 2 8

2 3 7 9 8 1 4 1

9 9 1 8 4 2 7 9

Vereinfachte Feature Vector Beispiele

2 5 6 3 2

Feature Vector für „Apfel“



3 1 4 4 5

Feature Vector für „Pfirsich“



9 4 7 9 1

Feature Vector für „Giraffe“



Was erwartet Dich in diesem Kapitel?

Grundbegriffe

Tools


... Daten ... woher?

Datentypen

Abstands- und Ähnlichkeitsmaße


Ähnlichkeitseigenschaft

- Der VektorABSTAND ist bei *ähnlichen* Daten geringer.
- Somit können Vektoren zur Suche nach ähnlichen Daten verwendet werden.



Ähnlichkeit von Objekten

- Vorhandensein von Abstandsmaßen
- Ähnlichkeit und Ermitteln der Klassenzugehörigkeit an einem Beispiel
(zweidimensionaler Datensatz, 2 Klassen, euklidische Distanz, k-Nearest Neighbour)



mit $k=1$ Klasse 1 ● (1:0) mit $k=5$ Klasse 2 ● (3:2)

Entscheidend für das Ergebnis ist in diesem Fall die geschickte Wahl von k

Abstandsmaß

Um Datensätze miteinander vergleichen und bspw. „ähnliche“ Objekte zusammenfassen zu können (clustering), muss die Ähnlichkeit von Datensätzen bestimmt werden.

Realisierung erfolgt über ein **Abstandsmaß**, x und y sind 2 Datensätze:

$dist(x, y)$: Abstand der Datensätze x und y

Eine Abstandsfunktion (auch Distanzfunktion genannt) sollte folgende Eigenschaften erfüllen:

- $dist(x, x) = 0$
- $dist(x, y) > 0$, wenn $x \neq y$
- $dist(x, y) = dist(y, x)$
- $dist(x, y) \leq dist(x, z) + dist(z, y)$

Distanzfunktionen – numerische Werte (1)

- Hamming-Distanz
zählt an wievielen Stellen sich Datensätze unterscheiden
$$\text{dist}_H(x, y) = \text{count}_i(v_i \neq w_i)$$
- Euklidische Distanz
Abstand zweier Punkte im n-dimensionalen Raum
$$\text{dist}_E(x, y) = \sqrt{\sum_i (x_i - y_i)^2}$$
- Quadrierte euklidische Distanz
(auch quadratische euklidische Distanz)
$$\text{dist}_{QE}(x, y) = \sum_i (x_i - y_i)^2$$
- Gewichtete Euklidische Distanz
Gewichte zum Hervorheben von Attributen, je höher das Gewicht, umso größer der Einfluss auf den Abstand
$$\text{dist}_{EW}(x, y) = \sqrt{\sum_i w_i * (x_i - y_i)^2}$$
- Manhattan-Distanz
die Dimensionen werden separat betrachtet
$$\text{dist}_{Man}(x, y) = \sum_i (|x_i - y_i|)$$
- Maximum-Distanz
(auch Tschebyscheff-Distanz)
die Dimensionen werden separat betrachtet
$$\text{dist}_{Max}(x, y) = \max_i (|x_i - y_i|)$$
- Mahalanobis-Distanz, ...

Distanzfunktionen – numerische Werte (2)

Minkowski-Distanz

$$\text{dist}_{Mink}^n(x, y) = \sqrt[n]{\sum_i |x_i - y_i|^n}$$

Mit $n \rightarrow \infty$ ergibt die Minkowski-Distanz die Maximum-Distanz!

$$\lim_{n \rightarrow \infty} \text{dist}_{Mink}^n = \text{dist}_{Max}$$

Mit $n=1$ ergibt die Minkowski-Distanz die Manhattan-Distanz!

$$\text{dist}_{Mink}^1(x, y) = \sqrt[1]{\sum_i |x_i - y_i|^1} = \sum_i (|x_i - y_i|)$$

Distanzfunktionen – Zeichenketten

- Hamming-Distanz

$$\text{dist}_H(x, y) = \text{count}_i(x_i \neq y_i)$$

- Levenshtein-Distanz
(Editierdistanz)

Minimal benötigte Anzahl von Einfüge-, Lösch- und Ersetzungs-Operationen einzelner Buchstaben, um die erste Zeichenkette in die zweite Zeichenkette umzuwandeln

Beispiel Levenshtein-Distanz zwischen den Wörtern *kitten* und *sitting*

1. Ersetze k mit s: kitten => sitten
2. Ersetze e mit i: sitten => sittin
3. Einfügen von g: sittin => sitting

=> Levenshtein-Distanz = 3

Distanzfunktionen – Geodaten

Haversine Distance

$$\text{dist}(x, y) = 2r \arcsin \left(\sqrt{\sin^2 \left(\frac{x_{\text{lat}} - y_{\text{lat}}}{2} \right) + \cos(x_{\text{lat}}) \cos(y_{\text{lat}}) \sin^2 \left(\frac{x_{\text{long}} - y_{\text{long}}}{2} \right)} \right)$$

dist = Abstand zwischen 2 Punkten (x und y) auf einem Kreis auf einer Kugel

r = Radius der Kugel


lat = Latitude, Geographische Breite

long = Longitude, Geographische Länge

... wäre die Erde eine Kugel, dann wäre r = 6371km ...

https://scikit-learn.org/stable/modules/generated/sklearn.metrics.pairwise.haversine_distances.html

Beispiel 1 Distanzfunktionen



$$dist_H = 2$$

$$dist_E \approx 8.9$$

$$dist_{Man} = 12$$

$$dist_{Max} = 8$$

Beispiel 2 Hamming-Distanz

$x = (\text{maria}, 28, \text{ledig})$

$y = (\text{ulf}, 29, \text{ledig})$

$$\text{dist}_H(x, y) = 2$$

die Hamming-Distanz erkennt nicht, dass sich das Alter nur gering unterscheidet,
kein Unterschied von $28 \neq 29$ und $28 \neq 95$

Ähnlichkeitsmaß (1)

Darauf aufbauend kann die Ähnlichkeit definiert werden:

simil(x, y): Ähnlichkeit der Datensätze x und y mit
$$\text{simil}(x, y) = f(\text{dist}(x, y))$$

Ein Ähnlichkeitsmaß sollte folgende Eigenschaften erfüllen:

- $\text{simil}(x, y) \geq 0$
- $\text{simil}(x, y) = \text{simil}(y, x)$
- $\text{simil}(x, y) \leq \text{simil}(x, x)$

Ein Ähnlichkeitsmaß heißt normiert, wenn gilt

$$\text{simil}(x, x) = 1$$

Ähnlichkeitsmaß (2)

Es gibt weitere Ähnlichkeitsmaße, die nicht auf Distanzmaßen beruhen (Cosinus, Dice, Jaccard, ...)


Beispiel Cosinus:

$$\cos(x, y) = \frac{x * y}{\sqrt{\sum_i x_i^2 * \sum_i y_i^2}}$$

- misst Ähnlichkeiten von Vektoren,
- Ergebnis liegt zwischen -1 (unähnlich) und 1 (ähnlich),
- nur auf metrische Daten anwendbar

Trade-off Erklärbarkeit und Komplexität (Auswahl)

Zunehmende Erklärbarkeit



White Box-Modelle

Es ist erklärbar, wie die Vorher- und Voraussage durch wissenschaftliche Verallgemeinerung (Prädiktion) zustande kommt und was die Einflussvariablen sind.

Black Box-Modelle

Nur die Beziehungen zwischen Eingabe und Ausgabe sind sichtbar. Keine Schätzung über die Bedeutung der einzelnen Merkmale für das Modell. Keine Information, wie die Merkmale zusammenwirken.

Quelle: <https://towardsdatascience.com/machine-learning-interpratability-techniques-662c723454f3>