



Hochschule für Angewandte Wissenschaften Hamburg
Hamburg University of Applied Sciences

Computational Intelligence

Prof. Dr.-Ing. Sabine Schumann

Fakultät Informatik und Digitale Gesellschaft

Data Mining – Anwendungsklassen

Welche Anwendungsklassen?

- Eine große Datenmenge und man weiß nicht genau, wonach man eigentlich sucht: **Clustering** (Bilden von Gruppen ähnlicher Objekte). Wenn Cluster gefunden wurden, so können diese benannt werden, man bildet Klassen.
- Wenn die Daten bereits klassifiziert vorliegen (bspw. schlechte, gute, hervorragende Kunden), benötigt man Techniken, um neue Kunden einzuordnen, also eine Vorhersage zu treffen, die Technik dazu ist die **Klassifikation**.
- Ähnlich dazu ist die **Vorhersage numerischer Werte**.
- Wenn man Beziehungen zwischen Attributen herstellen möchte (bspw. wer A kauft, kauft auch B), wird die **Assoziationsanalyse** verwendet.
- **Text-Mining** ...
- **Web-Mining** ...

Kategorien basierend auf Merkmals-Vektoren (feature-vector)

Normalerweise unsupervised

- Clustering
- Outlier detection

Normalerweise supervised

- Klassifikation
- Regression

Klassifikation

- überwachtes Lernen
- Ziel ist die Einteilung eines Gegenstandsbereiches in Klassen.



- Aufteilen der bereits in klassifizierter Form vorliegenden Datenmenge in Trainings- und Testdaten
- Anhand der Trainingsdaten wird ein Modell aufgebaut.
D.h. sowohl die Klassen als auch die Zugehörigkeit der Testobjekte zu ihren jeweiligen Klassen sind bekannt.
- Innerhalb eines Lernprozesses wird ein Klassifikationsmodell angelernet, welches beschreibt, wie die Eigenschaften der vorliegenden Trainingsdaten die Einordnung in bestimmte Klassen beeinflussen.
- Das Modell wird anhand von Testdaten geprüft ggf. korrigiert, bis nur noch eine geringe Fehlerabweichung existiert.
- Sobald ein gutes Klassifikationsmodell vorliegt, kann die Einordnung neuer Datensätze in die vorgegebenen Klassen erfolgen.

Bildquelle: <https://www.lesen.net/wp-content/uploads/2014/01/zettelkasten-347x195.jpg>

Klassifikationsverfahren (1)

Unterscheidung

- instanzbasierte Verfahren
 - Kategorisiert direkt anhand der vorhandenen Trainingsdaten
 - Sucht Daten in der Trainingsmenge mit geringem Abstand

einfaches (kein) Training, aufwändige Klassifikation

- Modell-basierte Verfahren
 - Lernt abstraktes Modell aus Trainingsdaten
 - Modell generalisiert Daten auf relevante Kernmerkmale

aufwändiges Training, einfache Klassifikation

Klassifikationsverfahren (2)

Verfahren

- k-Nearest-Neighbour
- Entscheidungsbäume
- Bayesverfahren (Naive Bayes, Bayessche Formel und bedingte Wahrscheinlichkeiten)
- vorwärtsgerichtete neuronale Netze (feedforward KNN)
- Support Vector Machines (SVM)
- Random Forest
- Klassifikationsregeln
- Fuzzy-Systeme
- ...

Klassifikation – Veranschaulichung – Lernphase

Trainingsproben



Klassifikationsalgorithmus




Klassifikationsregeln

Beispiel Klassifikationsregel:

WENN Alter=31...40 **UND** Einkommen hoch
DANN Kreditwürdigkeit=sehr gut

			KLASSE
Name	Alter	Einkommen	Kreditwürdigkeit
Alice	≤30	niedrig	normal
Bob	≤30	niedrig	sehr gut
Charly	31...40	hoch	sehr gut
Diana	>40	mittel	normal
Edward	>40	mittel	normal
Florence	31...40	hoch	sehr gut
...	...	...	...



Klassifikation – Veranschaulichung – Test- und Anwendungsphase

Testdaten:

Name	Alter	Einkommen	Kreditwürdigkeit	Bewertung durch Klassifikationsregeln
Grace	31...40	hoch	sehr gut	sehr gut
Herbert	31...40	hoch	normal	sehr gut
Ian	>40	hoch	sehr gut	sehr gut
...	...	...	...	...

Neue Daten:

Name	Alter	Einkommen	Kreditwürdigkeit	Bewertung durch Klassifikationsregeln
James	31...40	hoch	??	sehr gut
Keith	...	...	...	...
...	...	...	...	...

Klassifikationsergebnis

Das Lernverfahren muss erkennen, welche der vorhandenen Eigenschaften (Name, Einkommen, Alter) bestimmend für die Klasseneinordnung (Kreditwürdigkeit) sind.

Das Ergebnis muss nicht immer eine eindeutige Klasse sein.
Es ist durchaus auch **eine Wahrscheinlichkeit für jede Klasse** von Interesse.

Klassifikation – typische Beispiele

- Vorhersage von Tsunami-, Erdbebenwahrscheinlichkeiten
- Reagiert ein bestimmter Kunde auf eine Werbeaktion?
- Kreditwürdigkeit
- Zeichenerkennung bei Adressen, Kfz-Zeichen
- Data Mining Cup 2006, 2008, 2013, 2014 (und weitere)
- ...

Klassifikation – spezielles Beispiel (1)

Herzinfarkt Schnelldiagnose in der Notaufnahme

Stichprobe:

Patienten mit Brustschmerz in der Notaufnahme in Edinburgh (n=1252) und Sheffield (n=500)

45 Merkmale: age, smoker, ex-smoker, family history of MI, diabetes, high blood pressure, lipids, retrosternal pain, chest pain major symptom, left chest pain, right chest pain, back pain, left arm pain, right arm pain, pain affected by breathing, postural pain, chest wall tenderness, sharp pain, tight pain, sweating, shortness of breath, nausea, vomiting, syncope, episodic pain, worsening of pain, duration of pain, previous angina, previous MI, pain worse than prev. Angina, crackles, added heart sounds, hypoperfusion, heart rhythm, left vent. hypertrophy, left bundle branch block, ST elevation, new Q waves, right bundle branch block, ST depression, T wave changes, ST or T waves abnormal, old ischemia, old MI, sex

Quelle: Tsien, C., Fraser, H., Long, W. and Kennedy, R. Medinfo. v9. 493-497., 1998.: Using classification tree and logistic regression methods to diagnose myocardial infarction
<http://groups.csail.mit.edu/medg/people/hamish/medinfo-chris.pdf>

Klassifikation – spezielles Beispiel (2)

Lösung mittels Entscheidungsbaum:

nur 10, nicht 45 Merkmale werden für die Schnelldiagnose benötigt.

Wie gut ist der Baum?

- **Sensitivity = 81.4%**
- **Specificity = 92.1%**
- **PPV = 72.9%**
- **Accuracy = 89.9%**
- **Sensitivität** = $TP / (TP + FN)$: von 100 echten MI nur 81 erkannt (und 19 nicht!! und damit nicht behandelt)
- **Spezifität** = $TN / (TN + FP)$: von 100 Gesunden wurden 92 als gesund erkannt
(und 8 als krank und umsonst behandelt)
- **PPV**: Positive Predictive Value = $TP / (TP + FP)$ von 100 angezeigten MI waren 73 echt
- **Accuracy** = $(TN + TP) / \text{Alle}$: von 100 Entscheidungen waren 90 richtig

Überblick Klassifikations-Algorithmen

Algorithmus	Vorteile	Nachteile
Logistische Regression	- Einfaches Modell - Nicht erweiterbar	Erfordert Encodierung nominaler feature
kNearest Neighbour	- Kein Training - Dadurch einfache Erweiterung der Datenbasis	- Benötigt Distanzfunktion entsprechend der Datentypen - Anfällig für Overfitting bei leerem Feature-Raum
Entscheidungsbäume	- Einfache Interpretation - Automatische Feature-Selektion nach Informationsgehalt	- Neichtes Overfittig, daher Pruning nötig - Diskretisierung kontinuierlicher Features
Naive Bayes	- Einfacher, effizienter Algorithmus - Schnelles Training der bedingten Wahrscheinlichkeiten - Gut für relativ kleine Datensätze	- Annahme der Unabhängigkeit der Features - Diskretisierung kontinuierlicher Features
Support Vector Machines (SVM)	Kernel-Methoden für nicht linear trennbare Probleme	Erfordert Encodierung nominaler Feature
Multilayer Perceptron (MLP)	- Flexibel zu dimensionieren - Theoretisch alle Funktionen erlernbar - Automatische Feature-Extraction - Hohe Parallelisierbarkeit	- Aufwendiges Training - Komplexe Netze benötigen viele Daten - Erfordert Encodierung nominaler Feature - Schlecht interpretierbar
Ensemble SVM / Random Forrest	Ensemble meist genauer als einzelner Classifier	- Komplexer Meta-Classifer - Random Forrest verliert Interpretierbarkeit von Entscheidungsbäumen

Clustering

unüberwachtes Lernen

Ziel ist es eine gegebene Datenmenge in Teilmengen (Cluster) zu zerlegen, wobei die Objekte innerhalb eines Clusters „ähnlich“ und mit Objekten anderer Cluster „unähnlich“ sein sollen.



Wie misst man Ähnlichkeit?



benötigt wird eine Distanz- oder Abstandsfunktion (siehe Data Mining – Grundlagen)

Bildquelle: http://static.zoonar.de/img/www_repository3/cf/34/51/10_13e59be813284db2dcd377485c4b5e97.jpg

Clustering / Clusteringanalyse / Dimensionality Reduction

- ähnlich der Klassifikation, Gruppierung anhand von Ähnlichkeiten
- eine gegebene Instanzenmenge M eines Instanzenraumes I wird in Teilmengen (Cluster) aufgeteilt
- Objekte, die zum selben Cluster gehören, sollen möglichst ähnlich (homogen) sein
- Objekte verschiedener Cluster sollen möglichst unähnlich zueinander sein
- Neben der Instanzenmenge werden eine Distanzfunktion zur Bestimmung der Ähnlichkeit zweier Datensätze, sowie eine Qualitätsfunktion, die einen Vergleich von Clusterbildungen ermöglicht, benötigt
- Grundannahme: **Ähnliche** Daten haben einen **geringen Abstand**
- Training anhand von ungelabelten Daten
- Lernen von Strukturen in Daten
- KEINE eindeutig korrekte Lösung




Abbildung Cleve, Lämmel: Data Mining, S. 63

Clusteringverfahren

- Partitionierende Verfahren
 - k-Means
 - k-Medoid
 - Fuzzy-C-Means
- Erwartungsmaximierung
- Hierarchische (agglomerative) Verfahren
- Dichtebasierte Verfahren
 - DBSCAN
- Gitterbasierte Verfahren
- Minimum Spanning Tree (MST und MCST) (Algorithmus von Kruskal)
- künstlicher neuronaler Netze, bspw. Selbstorganisierende Karten (SOM), neuronale Gase, adaptive Resonanz Theorie (ART-Netze)
- ...

Clustering

Der Abstand der Objekte innerhalb eines Clusters soll kleiner sein als der Abstand zu den Objekten anderer Cluster. Distanzfunktion $\text{dist}(a,b)$.

$$\forall C_i, C_j \text{ mit } i \neq j \in C: \forall x_k, x_l \in C_i, x_m \in C_j : \text{dist}(x_k, x_l) < \text{dist}(x_k, x_m)$$

Eine Qualitätsfunktion beschreibt die Güte des Clusterings.





Abbildung Cleve, Lämmel: Data Mining, S. 63

Clustering – typische Beispiele


- Finden „gleichartiger“ Kunden, um gezielte Angebote zu entwickeln
- Einer Kundengruppe ein gezieltes Angebot zukommen lassen
- Zwischen Clustern „wandernde“ Kunden erkennen
- Entwicklungstendenzen der sozialen Stadtentwicklung
- Finden von Buchstabengruppen (die ähnliche Bilder haben), um Klassifikatoren zu erstellen
- Betrugsversuche erkennen: untypische Transaktionen außerhalb bekannter Cluster
- ...

Outlier Detection / Anomaly Detection

Ermittlung von untypischen Daten

Anwendung:


- Entdeckung von Missbrauch bei Kreditkarten, Telekommunikation, ...
- Datenbereinigung (bspw. Messfehler)



Bildquelle: <https://medium.com/@mehulved1503/outlier-detection-and-anomaly-detection-with-machine-learning-caa96b34b7f6>

Dimensionsreduktion / Dimensionality Reduction

Datenreduktion durch Dimensionsreduktion



Sebastian Raschka: Machine Learning mit Python, 2018, S. 32

Dimensionsreduktion und Visualisierung mit t-SNE (CalTech-101 Dataset)



t-Distributed Stochastic Neighbor Embedding (t-SNE)

Laurens van der Maaten, 2016

Numerische Vorhersage

- sowohl überwachtes als auch unüberwachtes Lernen
- Ziel ist die Annäherung (Approximation) einer Funktion aus Beispielen.
- Auf Basis bekannter Instanzbeschreibungen und Funktionswerten sollen Werte zukünftiger, bislang unbekannter Instanzbeschreibungen berechnet werden.

Klassifikation vs. Regression

kontinuierliche Zielvariable $y \in \mathbb{R}$



Regressions-Problem

Zielvariable nimmt kleine Anzahl
diskreter Werte oder Label an
 $y \in \{\text{gut, neutral, schlecht}\}$



Klassifikation

Numerische Vorhersage – typische Beispiele

- Vorhersage von Verkaufszahlen zur Lageroptimierung
- Vorhersage von Aktienkursen
- ...

Verfahren für numerische Vorhersage

- Lineare Regression
beschreibt den Trend bzw. den durchschnittlichen Zusammenhang zwischen metrischen Attributen
- Regressionsbäume
- Künstliche Neuronale Feedforward Netze
- ...





Abbildung nach Cleve, Lämmel: Data Mining, S. 68

Beispiele

- Wie viele Prüfungsbögen sollen zur Nachprüfung gedruckt werden?
- Aus den Konfigurationsdaten eines PCs den Performancewert vorhersagen.
Welches Merkmal hat den größten Einfluss auf die Performance?
- Vorhanden: Studierendendatensätze mit Notenprofil.
Gesucht: Modell zur Vorhersage der Note der Abschlussarbeit.

Assoziationsanalyse (1)

- unüberwachtes Lernen
- Scannen von Produkten im Laden mit Hilfe von Lesegeräten durch Barcodetechnik
- dadurch Dokumentation des Kaufverhaltens von Kund*innen
- diese Daten zur Analyse verwenden, um
 - Waren optimal anzuordnen,
 - die Kund*innen zu kategorisieren,
 - Welche Produkte sind Ladenhüter?
 - ...
- die reine Warenkorbanalyse entwickelte sich letztendlich zur (allgemeineren) Assoziationsanalyse



Assoziationsanalyse (2)

- Versuch Datenbereiche in den Daten zu finden, in denen mehrere Werte mit hoher Wahrscheinlichkeit gleichzeitig auftreten
Ereignis A und B treten oft gemeinsam auf:
Finden von Abhängigkeiten von Objekten bspw. „Wer A kauft, kauft auch B“
- Warenkorbanalyse-Problem „Wer Chips kauft, kauft auch häufig (85%) Cola“
- dient neben der Analyse von Regelmäßigkeiten auch zur Prognose
- Aufstellen von Assoziationsregeln
- zählt zu den beliebtesten Data Mining Verfahren

Assoziationsanalyse – Verfahren

- A-Priori-Verfahren
- Frequent Pattern Growth
- adaptive Resonanz Theorie (ART-Netze)
- ...

Anwendungsklasse Text Mining

- Ca. 80% der nützlichen Informationen einer Firma liegen in Form von unstrukturierten Texten vor: Emails, Memos, Umfragen, Serviceberichte, ...
- datenschutztechnisch durchaus kritisch zu betrachten
- Abkürzungen müssen erkannt und substituiert werden
- Verwendung von Abstandsmaßen
- Schlüsselwörter, Verteilung von Wörtern nach Anzahl ihres Vorkommens, ...

Anwendungsklasse Web Mining

- Mustererkennung im World Wide Web
- Unterscheidung zwischen
 - Inhalt (**Web Content**)
Informationen aus Texten, Bildern, Audios, Videos, Hyperlinks, Webseiten, ...
 - Nutzung (**Web Usage**)
Entdeckung von Verhaltensmustern bei der Nutzung des Internets, Analyse der Protokolldateien von Webservern zum Verhalten bzw. den Interessen der Server-Besucher
 - Link-Strukturen (**Web Structure**)
wird von Suchmaschinen verwendet.
Links und Linkstrukturen werden analysiert
Beispiel: welche Seite ist populär, Analyse von Nutzer*innen durch Verlinkung der gleichen Seite(n)