



Hochschule für Angewandte Wissenschaften Hamburg
Hamburg University of Applied Sciences

Computational Intelligence

Prof. Dr.-Ing. Sabine Schumann

Fakultät Informatik und Digitale Gesellschaft


Klassifikation
Entscheidungsbäume

Was erwartet Dich in diesem Kapitel?

Regeln → UND/ODER-Bäume

Entscheidungsbäume

Overfitting, Underfitting, Pruning




Was erwartet Dich in diesem Kapitel?

Regeln → UND/ODER-Bäume

Entscheidungsbäume

Overfitting, Underfitting, Pruning



Klassifizierungsbeispiel

Tag	Outlook	Temperature	Humidity	Windy?	Sailing?
1	sunny	hot	high	true	no
2	sunny	hot	high	false	no
3	overcast	hot	high	true	yes
4	rainy	mild	high	true	yes
5	rainy	cool	normal	true	yes
6	rainy	cool	normal	false	no
7	overcast	cool	normal	false	yes
8	sunny	mild	high	true	no
9	sunny	cool	normal	true	yes
10	rainy	mild	normal	true	yes
11	sunny	mild	normal	false	yes
12	overcast	mild	high	false	yes
13	overcast	hot	normal	true	yes
14	rainy	mild	high	false	no

... als Regeln

WENN outlook=sunny UND temperature=hot UND humidity =high UND windy=true

DANN sailing=no

WENN outlook=sunny UND temperature=hot UND humidity =high UND windy=false

DANN sailing=no

WENN outlook=overcast UND temperature=hot UND humidity =high UND windy=true

DANN sailing=yes

WENN outlook=rainy UND temperature=mild UND humidity =high UND windy=true

DANN sailing=yes

WENN outlook=rainy UND temperature=cool UND humidity =normal UND windy=true

DANN sailing=yes

WENN outlook=rainy UND temperature=cool UND humidity =

WENN outlook=overcast UND temperature=cool UND humidit

WENN outlook=sunny UND temperature=mild UND humidity =

WENN outlook=sunny UND temperature=cool UND humidity =

WENN outlook=rainy UND temperature=mild UND humidity =

WENN outlook=sunny UND temperature=mild UND humidity =

WENN outlook=overcast UND temperature=mild UND humidit

WENN outlook=overcast UND temperature=hot UND humidity

WENN outlook=rainy UND temperature=mild UND humidity =

Tag	Outlook	Temperature	Humidity	Windy?	Sailing?
1	sunny	hot	high	true	no
2	sunny	hot	high	false	no
3	overcast	hot	high	true	yes
4	rainy	mild	high	true	yes
5	rainy	cool	normal	true	yes
6	rainy	cool	normal	false	no
7	overcast	cool	normal	false	yes
8	sunny	mild	high	true	no
9	sunny	cool	normal	true	yes
10	rainy	mild	normal	true	yes
11	sunny	mild	normal	false	yes
12	overcast	mild	high	false	yes
13	overcast	hot	normal	true	yes
14	rainy	mild	high	false	no

... als UND/ODER-Baum

Wie wir aus dem Logik-Kapitel wissen: Regeln lassen sich mittels UND/ODER-Bäumen darstellen

Nachteile:

- Alle Regeln erfasst?
- Welcher Attributwert wird die Wurzel?
- Welches Attribut / welcher Attributwert an welcher Stelle im Baum?
- Es kommt ein neues Attribut hinzu ...
- ... ein Attribut(wert) wird wegen Nichtrelevanz nicht mehr betrachtet
- metrische Werte?




Was erwartet Dich in diesem Kapitel?

Regeln → UND/ODER-Bäume

Entscheidungsbäume

- Informationsgewinn
- Informationsgehalt
 - Entropie
 - Gini-Index
 - Klassifikationserror

Overfitting, Underfitting, Pruning



Klassifikation mittels Entscheidungsbäumen (1)

Entscheidungsbäume aufzustellen ist ein Verfahren, das im Data Mining für die Anwendungsklasse Klassifikation verwendet werden kann.

- weit verbreitetes transparentes Modell
- häufige Modellierungsart
- Grundidee des Lernalgorithmus ist einfach
- wird durch viele Data Mining Werkzeuge unterstützt
- Sehr erfolgreiches Lernverfahren
- Induktives Lernen
- Vorhersage aus einem durch Trainingsdaten erstellten Modell → *modellbasiertes Verfahren*



Wir beschränken uns hier im Kurs auf **duale Ja/Nein Entscheidungen**.

Klassifikation mittels Entscheidungsbäumen (2)

- Objekte sind durch Mengen von Attribut/Wert Paaren beschrieben
- für jedes Objekt liefert der Entscheidungsbaum eine Entscheidung, welcher Klasse es zuzuordnen ist

Idee

- Jeder innere Knoten testet ein Attribut.
- Jeder Zweig repräsentiert einen Attributwert.
- Jedes Blatt ist mit einem Wahrheitswert belegt, weist also eine Klassifikation zu.
- Ausgehend von der Wurzel werden die Attribute für ein neues Objekt untersucht, bis ein Blattknoten erreicht ist, der die Klasse zuordnet.

Beschreiben

Vorhersagen

Entscheidungsbäume

Was macht einen guten Baum aus?

- gültig,
- übersichtlich (flach, wenige Knoten, gleichmäßige Datendichte ...),
- „kleiner korrekter Baum“.

Wie finden ????

Klassifizierungsbeispiel

Tag	Outlook	Temperature	Humidity	Windy?	Sailing?
1	sunny	hot	high	true	no
2	sunny	hot	high	false	no
3	overcast	hot	high	true	yes
4	rainy	mild	high	true	yes
5	rainy	cool	normal	true	yes
6	rainy	cool	normal	false	no
7	overcast	cool	normal	false	yes
8	sunny	mild	high	true	no
9	sunny	cool	normal	true	yes
10	rainy	mild	normal	true	yes
11	sunny	mild	normal	false	yes
12	overcast	mild	high	false	yes
13	overcast	hot	normal	true	yes
14	rainy	mild	high	false	no

Entscheidungsbaum – wie finden?

- Anzahl der möglichen Entscheidungsbäume zu einem Problem ist gigantisch hoch
- William of Occam:
Ein Modell ist umso besser, je einfacher es ist (Occam's Razor)
- **T**op **D**own **I**nduction of **D**ecision **T**rees (**TDIDT**):
Aufbau des Baumes von oben (Wurzel) nach unten
Verfahren:
 - ID3 (Iterative Dichotomiser 3) (1986) von John Ross Quinlan,
 - C4.5 (1993) von John Ross Quinlan
 - C5.0 von John Ross Quinlan
 - CART (1984) von Leo Breiman et al
 - NewID, ID5R, CHAID, CLS, LCLRD, AQ15, ...



William of Occam
ca. 1285-1349



J. Ross Quinlan

Bildquellen: <https://en.wikipedia.org/>
<https://www.rulequest.com/Personal/>

Auswahl des Wurzelattributs


Start mit dem Wurzelattribut

Aber: Welches Attribut ist das geeignetste?

- manuell
Nutzer*in gibt Attribut vor
- zufällig
mittels Zufallsgenerator
- berechnet
Suche nach einem Attribut, welches einen Baum mit geringem Umfang erzeugt

Entscheidungsbaum – bestes Wurzelattribut? (1)

Unsere Segeldaten:



Entscheidungsbaum – bestes Wurzelattribut? (2)

Welches Attribut hat den höchsten Informations**gewinn** (Gain)?

$$\text{gewinn}(D_p, a) = I(D_p) - \sum_{j=1}^m \frac{N_j}{N_p} * I(D_j)$$

I (Informations**gehalt**) kann ermittelt werden mittels

- Entropie,
- Gini-Index oder
- Klassifikationserror

D sind Mengen von Datensätzen

- D_p : Menge der Daten des gesamten Teilbaums
- D_j : Menge der Daten mit Attribut-Ausprägung a_j

N sind die Anzahlen der Datensätze

- N_p : Anzahl Datensätze im gesamten Teilbaum (in Menge D_p)
- N_j : Anzahl Datensätze mit Attribut-Ausprägung a_j (in Menge D_j)

Entropie, Gini-Index, ...

Informations**gehalt** bezogen auf Attribut und Datenmenge

Entropie:

$$I_{\text{Entropie}}(D) = \sum_{i=1}^n -h(z_i|D) * \log_2(h(z_i|D))$$

Gini-Index (auch Gini-Koeffizient):

$$I_{\text{Gini}}(D) = 1 - \sum_{i=1}^n h(z_i|D)^2$$


Klassifikationserror:

$$I_{\text{Error}}(D) = 1 - \max\{h(z_i|D)\}$$

h – relative Häufigkeit

z – Zielattribut

z_i – Wert des Zielattributes



Corrado Gini
1884 - 1965

Bildquelle: <http://matematica.unibocconi.it/sites/default/files/Gini.jpg>

Iteratives Erstellen des Entscheidungsbaumes

- I. Informationsgehalt aller (in unserem Beispiel 4) Attribute berechnen
Attribut mit dem höchsten Informationsgewinn wird Wurzel
- II. Teilen der Datenmenge in unterschiedliche Teilbäume
Anzahl der Teilbäume = Anzahl der Ausprägungen des Wurzelattributes
- III. Für jeden Teilbaum rekursiv mit I. fortfahren bis die Datenmenge des Teilbaumes nur noch komplett einer Klasse zuzuordnen ist

Segelbeispiel mittels Entropie (1)

Wir haben 4 Attribute, für diese muss der Informationsgewinn ausgerechnet werden:

$$\text{gewinn}(D_p, a) = I(D_p) - \sum_{j=1}^m \frac{N_j}{N_p} * I(D_j)$$

mit

$$I(D_p) = I_{\text{Entropie}}(D_p) = \sum_{i=1}^n -h(z_i|D_p) * \log_2(h(z_i|D_p))$$

1. einmaliges Berechnen von $I(D_p)$,
2. Berechnen von $I(D_j)$ für alle Ausprägungen des gewählten Attributes,
3. Einsetzen in die Gewinn-Formel.

Segelbeispiel mittels Entropie (2)

1. Berechnen von $I(D_p)$

Wir haben im gesamten Teilbaum D_p insgesamt 14 Datensätze,

$$N_p = 14$$

die sich nach ihrem Zielattribut z aufteilen in

$$z_1 = \text{Sailing}_1 = \text{yes} = 9 \quad \text{und} \quad z_2 = \text{Sailing}_2 = \text{no} = 5$$

und damit

$$h(z_1 \mid D_p) = 9/14 \quad \text{und} \quad h(z_2 \mid D_p) = 5/14$$

$$I(D_p) = I_{\text{Entropie}}(D_p) = \sum_{i=1}^n -h(z_i \mid D_p) * \log_2(h(z_i \mid D_p))$$

$$= -9/14 * \log_2(9/14) - 5/14 * \log_2(5/14)$$

$$= -0,6428 * -0,6376 - 0,3571 * -1,4856$$

$$= 0,4098 + 0,5305$$

$$= \mathbf{0,9403}$$


Tag	Outlook	Temperature	Humidity	Windy?	Sailing?
1	sunny	hot	high	true	no
2	sunny	hot	high	false	no
3	overcast	hot	high	true	yes
4	rainy	mild	high	true	yes
5	rainy	cool	normal	true	yes
6	rainy	cool	normal	false	no
7	overcast	cool	normal	false	yes
8	sunny	mild	high	true	no
9	sunny	cool	normal	true	yes
10	rainy	mild	normal	true	yes
11	sunny	mild	normal	false	yes
12	overcast	mild	high	false	yes
13	overcast	hot	normal	true	yes
14	rainy	mild	high	false	no

Segelbeispiel mittels Entropie – Wurzel? (1)

2. Berechnen von $I(D_j)$ für alle Ausprägungen des gewählten Attributes (outlook)

1. outlook = sunny

$$\begin{aligned} I(D_{\text{sunny}}) &= \sum_{i=1}^n -h(z_i | D_{\text{sunny}}) * \log_2(h(z_i | D_{\text{sunny}})) \\ &= -h(z_{\text{yes}} | D_{\text{sunny}}) * \log_2(h(z_{\text{yes}} | D_{\text{sunny}})) \\ &\quad -h(z_{\text{no}} | D_{\text{sunny}}) * \log_2(h(z_{\text{no}} | D_{\text{sunny}})) \\ &= -\frac{2}{5} * \log_2(\frac{2}{5}) - \frac{3}{5} * \log_2(\frac{3}{5}) \\ &= -0,4 * -1,3219 - 0,6 * -0,737 \\ &= 0,5288 + 0,4422 \\ &= \mathbf{0,971} \end{aligned}$$



2. outlook = overcast

$$\begin{aligned} I(D_{\text{overcast}}) &= \sum_{i=1}^n -h(z_i | D_{\text{overcast}}) * \log_2(h(z_i | D_{\text{overcast}})) \\ &= -h(z_{\text{yes}} | D_{\text{overcast}}) * \log_2(h(z_{\text{yes}} | D_{\text{overcast}})) \\ &= -1 * \log_2(1) = \mathbf{0} \end{aligned}$$

3. outlook = rainy

$$\begin{aligned} I(D_{\text{rainy}}) &= \sum_{i=1}^n -h(z_i | D_{\text{rainy}}) * \log_2(h(z_i | D_{\text{rainy}})) \\ &= -h(z_{\text{yes}} | D_{\text{rainy}}) * \log_2(h(z_{\text{yes}} | D_{\text{rainy}})) \\ &\quad -h(z_{\text{no}} | D_{\text{rainy}}) * \log_2(h(z_{\text{no}} | D_{\text{rainy}})) \\ &= \mathbf{0,971} \end{aligned}$$

Segelbeispiel mittels Entropie – Wurzel? (2)

outlook=sunny

$$I(D_{sunny}) = \mathbf{0,971}$$

outlook = overcast

$$I(D_{overcast}) = \mathbf{0}$$

outlook = rainy

$$I(D_{rainy}) = \mathbf{0,971}$$

Nun die Berechnungen für die anderen 3 Attribute Temperature, Humidity und Windy:

temperature = hot

$$I(D_{hot}) = \mathbf{1}$$

temperature = mild

$$I(D_{mild}) = \mathbf{0,9183}$$

temperature = cool

$$I(D_{cool}) = \mathbf{0,8112}$$

humidity = high

$$I(D_{high}) = \mathbf{0,9848}$$

humidity = normal

$$I(D_{normal}) = \mathbf{0,5913}$$

windy = true

$$I(D_{true}) = \mathbf{0,8112}$$

windy = false

$$I(D_{false}) = \mathbf{1}$$

Alle Werte sind durch Rundungen ggf. in der letzten Stelle ungenau.

Segelbeispiel mittels Entropie – Wurzel? (3)

3. Einsetzen in die Gewinn-Formel

$$\text{gewinn}(D_p, \text{outlook}) = I(D_p) - \sum_{j=1}^m \frac{N_j}{N_p} * I(D_j)$$

$$= 0,9403 - \left(\frac{5}{14} 0,971 + \frac{4}{14} 0 + \frac{5}{14} 0,971 \right)$$

$$= 0,9403 - (0,3468 + 0 + 0,3468)$$

$$= \mathbf{0,2467}$$

$$\text{gewinn}(D_p, \text{temperature}) = I(D_p) - \sum_{j=1}^m \frac{N_j}{N_p} * I(D_j)$$

$$= \mathbf{0,0287}$$

$$\text{gewinn}(D_p, \text{humidity}) = I(D_p) - \sum_{j=1}^m \frac{N_j}{N_p} * I(D_j)$$

$$= \mathbf{0,1518}$$

$$\text{gewinn}(D_p, \text{windy}) = I(D_p) - \sum_{j=1}^m \frac{N_j}{N_p} * I(D_j)$$


$$= \mathbf{0,0477}$$

Segelbeispiel mittels Entropie – Wurzel!


Unsere Segeldaten:

Attribut mit dem höchsten Informationsgewinn: outlook.

... und weiter geht's ...



Segelbeispiel mittels Entropie – Ebene 1



1. Ebene – Knoten 1.1



Tag	Outlook	Temperature	Humidity	Windy?	Sailing?
1	sunny	hot	high	true	no
2	sunny	hot	high	false	no
8	sunny	mild	high	true	no
9	sunny	cool	normal	true	yes
11	sunny	mild	normal	false	yes

Segelbeispiel mittels Entropie – Knoten 1.1 (1)

1. Berechnen von $I(D_p)$

Wir haben im gesamten Teilbaum D_p insgesamt 5 Datensätze,

$$N_p = 5$$

die sich nach ihrem Zielattribut z aufteilen in

$$z_1 = \text{Sailing}_1 = \text{yes} = 2 \quad \text{und} \quad z_2 = \text{Sailing}_2 = \text{no} = 3$$

und damit

$$h(z_1 \mid D_p) = 2/5 \quad \text{und} \quad h(z_2 \mid D_p) = 3/5$$

$$I(D_p) = I_{\text{Entropie}}(D_p) = \sum_{i=1}^n -h(z_i \mid D_p) * \log_2(h(z_i \mid D_p))$$

$$= -2/5 * \log_2(2/5) - 3/5 * \log_2(3/5)$$

$$= -0,4 * -1,3219 - 0,6 * -0,737$$

$$= 0,5288 + 0,4422$$

$$= \mathbf{0,971}$$


Tag	Outlook	Temperature	Humidity	Windy?	Sailing?
1	sunny	hot	high	true	no
2	sunny	hot	high	false	no
8	sunny	mild	high	true	no
9	sunny	cool	normal	true	yes
11	sunny	mild	normal	false	yes

Segelbeispiel mittels Entropie – Knoten 1.1 (2)

Berechnen von $I(D_j)$ für alle Ausprägungen des gewählten Attributes (temperature)

1. temperature = hot

$$\begin{aligned} I(D_{hot}) &= \sum_{i=1}^n -h(z_i|D_{hot}) * \log_2(h(z_i|D_{hot})) \\ &= -h(z_{yes}|D_{hot}) * \log_2(h(z_{yes}|D_{hot})) \\ &\quad -h(z_{no}|D_{hot}) * \log_2(h(z_{no}|D_{hot})) \\ &= 0 - 1 * \log_2(1) \\ &= \mathbf{0} \end{aligned}$$



2. temperature = mild

$$\begin{aligned} I(D_{mild}) &= \sum_{i=1}^n -h(z_i|D_{mild}) * \log_2(h(z_i|D_{mild})) \\ &= -h(z_{yes}|D_{mild}) * \log_2(h(z_{yes}|D_{mild})) \\ &= -1/2 * \log_2(1/2) - 1/2 * \log_2(1/2) \\ &= -0,5 * (-1) - 0,5 * (-1) \\ &= 0,5 + 0,5 = \mathbf{1} \end{aligned}$$

3. temperature = cool

$$\begin{aligned} I(D_{cool}) &= \sum_{i=1}^n -h(z_i|D_{cool}) * \log_2(h(z_i|D_{cool})) \\ &= -h(z_{yes}|D_{cool}) * \log_2(h(z_{yes}|D_{cool})) \\ &\quad -h(z_{no}|D_{cool}) * \log_2(h(z_{no}|D_{cool})) \\ &= -1 * \log_2(1) - 0 * \log_2(0) \\ &= -1 * 0 - 0 \\ &= \mathbf{0} \end{aligned}$$

Segelbeispiel mittels Entropie – Knoten 1.1 (3)

temperature = hot

$$I(D_{hot}) = 0$$

temperature = mild

$$I(D_{mild}) = 1$$

temperature = cool

$$I(D_{cool}) = 0$$

Nun die Berechnungen für die anderen 2 Attribute Humidity und Windy:

humidity = high

$$I(D_{high}) = 0$$

humidity = normal

$$I(D_{normal}) = 0$$

windy = true

$$I(D_{true}) = 0,9183$$

windy = false

$$I(D_{false}) = 1,0$$

Segelbeispiel mittels Entropie – Knoten 1.1 (4)

3. Einsetzen in die Gewinn-Formel

$$\text{gewinn}(D_p, \text{temperature}) = I(D_p) - \sum_{j=1}^m \frac{N_j}{N_p} * I(D_j)$$

$$= 0,571$$


$$\text{gewinn}(D_p, \text{humidity}) = I(D_p) - \sum_{j=1}^m \frac{N_j}{N_p} * I(D_j)$$

$$= 0,971$$

$$\text{gewinn}(D_p, \text{windy}) = I(D_p) - \sum_{j=1}^m \frac{N_j}{N_p} * I(D_j)$$

$$= 0,02$$

Segelbeispiel mittels Entropie – Knoten 1.2




1. Ebene – Knoten 1.2



Tag	Outlook	Temperature	Humidity	Windy?	Sailing?
3	overcast	hot	high	true	yes
7	overcast	cool	normal	false	yes
12	overcast	mild	high	false	yes
13	overcast	hot	normal	true	yes

Segelbeispiel mittels Entropie – Knoten 1.3 (1)



1. Ebene – Knoten 1.3



Tag	Outlook	Temperature	Humidity	Windy?	Sailing?
4	rainy	mild	high	true	yes
5	rainy	cool	normal	true	yes
6	rainy	cool	normal	false	no
10	rainy	mild	normal	true	yes
14	rainy	mild	high	false	no

Segelbeispiel mittels Entropie – Knoten 1.3 (2)

1. Berechnen von $I(D_p)$

Wir haben im gesamten Teilbaum D_p insgesamt 5 Datensätze,

$$N_p = 5$$

die sich nach ihrem Zielattribut z aufteilen in

$$z_1 = \text{Sailing}_1 = \text{yes} = 3 \quad \text{und} \quad z_2 = \text{Sailing}_2 = \text{no} = 2$$

und damit

$$h(z_1 \mid D_p) = 3/5 \quad \text{und} \quad h(z_2 \mid D_p) = 2/5$$

$$I(D_p) = I_{\text{Entropie}}(D_p) = \sum_{i=1}^n -h(z_i \mid D_p) * \log_2(h(z_i \mid D_p))$$

$$= -3/5 * \log_2(3/5) - 2/5 * \log_2(2/5)$$

$$= -0,6 * -0,737 - 0,4 * -1,3219$$

$$= 0,4422 + 0,5288$$

$$= \mathbf{0,971}$$

Tag	Outlook	Temperature	Humidity	Windy?	Sailing?
4	rainy	mild	high	true	yes
5	rainy	cool	normal	true	yes
6	rainy	cool	normal	false	no
10	rainy	mild	normal	true	yes
14	rainy	mild	high	false	no

Segelbeispiel mittels Entropie – Knoten 1.3 (3)

2. Berechnen von $I(D_j)$ für alle Ausprägungen des gewählten Attributes (temperature)

1. temperature = hot


$$I(D_{hot}) = \sum_{i=1}^n -h(z_i|D_{hot}) * \log_2(h(z_i|D_{hot})) = 0$$

2. temperature = mild

$$\begin{aligned} I(D_{mild}) &= \sum_{i=1}^n -h(z_i|D_{mild}) * \log_2(h(z_i|D_{mild})) \\ &= -h(z_{yes}|D_{mild}) * \log_2(h(z_{yes}|D_{mild})) \\ &\quad -h(z_{no}|D_{mild}) * \log_2(h(z_{no}|D_{mild})) \\ &= -\frac{2}{3} * \log_2(\frac{2}{3}) - \frac{1}{3} * \log_2(\frac{1}{3}) = \frac{2}{3} * (-0,585) - \frac{1}{3} * (-1,585) \\ &= 0,9183 \end{aligned}$$

3. temperature = cool

$$\begin{aligned} I(D_{cool}) &= \sum_{i=1}^n -h(z_i|D_{cool}) * \log_2(h(z_i|D_{cool})) \\ &= -h(z_{yes}|D_{cool}) * \log_2(h(z_{yes}|D_{cool})) \\ &\quad -h(z_{no}|D_{cool}) * \log_2(h(z_{no}|D_{cool})) \\ &= -\frac{1}{2} * (-1) - \frac{1}{2} * (-1) \\ &= 1 \end{aligned}$$



Segelbeispiel mittels Entropie – Knoten 1.3 (4)

temperature = hot

$$I(D_{hot}) = 0$$

temperature = mild

$$I(D_{mild}) = 0,9183$$

temperature = cool

$$I(D_{cool}) = 1$$

Berechnungen für Humidity und Windy ...

humidity = high

$$I(D_{high}) = 1$$

humidity = normal

$$I(D_{normal}) = 0,9183$$

windy = true

$$I(D_{true}) = 0$$

windy = false

$$I(D_{false}) = 0$$

Segelbeispiel mittels Entropie – Knoten 1.3 (5)

3. Einsetzen in die Gewinn-Formel

$$\text{gewinn}(D_p, \text{temperature}) = I(D_p) - \sum_{j=1}^m \frac{N_j}{N_p} * I(D_j)$$

$$= 0,02$$


$$\text{gewinn}(D_p, \text{humidity}) = I(D_p) - \sum_{j=1}^m \frac{N_j}{N_p} * I(D_j)$$

$$= 0,02$$

$$\text{gewinn}(D_p, \text{windy}) = I(D_p) - \sum_{j=1}^m \frac{N_j}{N_p} * I(D_j)$$

$$= 0,971$$

Segelbeispiel mittels Entropie – Knoten 2.1




2. Ebene – Knoten 2.1



Tag	Outlook	Temperature	Humidity	Windy?	Sailing?
1	sunny	hot	high	true	no
2	sunny	hot	high	false	no
8	sunny	mild	high	true	no

Segelbeispiel mittels Entropie – Knoten 2.2




2. Ebene – Knoten 2.2



Tag	Outlook	Temperature	Humidity	Windy?	Sailing?
9	sunny	cool	normal	true	yes
11	sunny	mild	normal	false	yes

Segelbeispiel mittels Entropie – Knoten 2.3




2. Ebene – Knoten 2.3



Tag	Outlook	Temperature	Humidity	Windy?	Sailing?
4	rainy	mild	high	true	yes
5	rainy	cool	normal	true	yes
10	rainy	mild	normal	true	yes

Segelbeispiel mittels Entropie – Knoten 2.4




2. Ebene – Knoten 2.4



Tag	Outlook	Temperature	Humidity	Windy?	Sailing?
6	rainy	cool	normal	false	no
14	rainy	mild	high	false	no

Segelbeispiel mittels Entropie – fertig!



Frage: segeln wir bei

outlook = sunny

temperature = hot

humidity = normal

windy = true




yes

C4.5 & C5.0

- Nachteil von ID3: kann keine numerischen Attribute behandeln
- C4.5 unterteilt numerische Attribute in Intervalle, die somit zu ordinalen Attributen werden, Pruning, ...

in Weka J48, RapidMiner: DecisionTree, KNIME:



- C5.0 ist kommerziell (die Single-Thread-Version wird unter den Bedingungen der GNU General Public License vertrieben), C-Code öffentlich, ähnlich zu C4.5 aber schneller, kleinere Entscheidungsbäume, Möglichkeit Attribute zu wichten

CART

- Classification and Regression Trees
- generiert werden Binärbäume,
d.h. bei jeder Entscheidung gehen nur 2 Kanten ab

Was erwartet Dich in diesem Kapitel?

Regeln → UND/ODER-Bäume

Entscheidungsbäume

- Informationsgewinn
- Informationsgehalt
 - Entropie
 - Gini-Index
 - Klassifikationserror

Overfitting, Underfitting, Pruning

Wie gut ist unser Modell?

Wie gut wird unser Modell in der (zukünftigen) Praxis funktionieren?

Die Prognosegüte (bspw. Fehlerrate, Erfolgsrate), die das Modell bei seiner Anwendung in der Praxis erreichen wird, kann **geschätzt** werden.

Unser ID3-Modell stimmt für die 14 Datensätze, wird aber in der Praxis für neue Daten häufig versagen.

Ausweg:

- andere Algorithmen
- mehr Daten, ...

Beispiel

Gesichtserkennungssoftware mit Altersvorhersage eines Hamburger Unternehmens, vorgestellt bei der Gründung von [aric e.V.](#) .

- Das Alter von Frauen wurde nahezu perfekt ermittelt (± 1 Jahr des realen Alters).
- Bei Männern lag die Abweichung für das vorhergesagte Alter bei durchschnittlich ± 10 Jahre.
- Bei Männern mit Bart lag die Abweichung der Vorhersage zum realen Alter noch höher, der schlechteste Wert waren über 30 Jahre.

Wie kommt das ???

Bildquelle: https://upload.wikimedia.org/wikipedia/commons/e/ef/Face_detection.jpg



Overfitting & Underfitting

- Generelles und **wichtiges Problem** beim Machine Learning
- aus der Reihenfolge durch den Informationsgewinn entsteht nicht unbedingt der beste bzw. kleinste Baum unter allen Möglichkeiten.
- Der Algorithmus ist “kurzsichtig”
 - die Suche nach Entscheidungsregeln ist daher auch nicht vollständig/umfassend
 - da der Baum via ID3 solange weiterwachsen soll, bis die Daten so eindeutig wie möglich erklärt sind, wird Overfitting geradezu provoziert
- Hypothese sagt **perfekt** Trainingsdaten vorher (alle Trainingsdaten werden korrekt klassifiziert)
- Keine Generalisierung hinsichtlich neuer Daten
- Beispiel:
 - Viele Parameter im Modell
 - Hypothese lernt Daten auswendig, gegebene Beobachtungen werden nur gespeichert, keine Muster erkannt

 Overfitting: Error bzgl. Trainingsdaten niedrig, bzgl. Testdaten hoch

 Underfitting: Error bzgl. Trainingsdaten hoch

Overfitting

- aus Daten generierte Entscheidungsbäume neigen zur Überanpassung (Overfitting)
- Neue Daten, die eine höhere Vielfältigkeit als die Trainingsdaten haben können, werden nicht mehr unter einer angemessenen Fehlerquote korrekt klassifiziert.
- ACHTUNG: Key-Spalten:
Überanpassung wird quasi erzwungen: Einbeziehen von „KundenID“ (eindeutige Nummer pro Kunde) so haben wir – bezogen auf das Klassifikationsergebnis – für jeden einzelnen Wert in dem Attribut eine Entropie von 0 zu erwarten, denn jeder ID beschreibt einen eindeutigen Fall (Kunde, Kundengruppe etc.).
Daraus folgt, dass der Informationsgewinn für dieses Attribut maximal wird. Der Baum wird sehr breit, jeder Wert der KundenID wäre ein einzelner Ast im Baum, der zu einem eindeutigen Ergebnis führt. Auf neue Daten (neue Kundennummern) ist der Baum nicht anwendbar.
- Große Bäume sind keine guten Bäume und ein Zeichen für Overfitting.
Verkleinerung durch erneutes Durchrechnen der Informationsgewinne und Kürzen von Verzweigungen (Verallgemeinerung), falls der Informationsgewinn zu gering ist.
Verwendung des Klassifikationsfehler (als Maß für die Unreinheit) und nicht Entropie oder Gini-Index.

Overfitting – wie verhindern? - Pruning

Künstliches (nachträgliches) Verkürzen der Entscheidungsbäume (Pruning)

2 Ansätze:

- Keine weiteren Unterbäume, wenn eine bestimmte Anzahl von Trainingsdaten unterschritten wird.
- Ersetzen bereits generierter Unterbäume durch ein Blatt.

Ein durch Pruning verkürzter Entscheidungsbaum kann für zukünftige Daten deutlich bessere Ergebnisse erzielen als ein Entscheidungsbaum, der alle Trainingsdaten korrekt klassifiziert.

Damit wird der Wunsch aufgegeben, dass unser Entscheidungsbaum die Trainingsdaten zu 100% korrekt vorhersagt. Dies kann jedoch ohnehin passieren, falls wir widersprüchliche Daten haben.

Random Forests

- Bei Random Forests (eine Form des Ensemble Learning) handelt es sich um eine Gemeinschaftsentscheidung der Klassenzugehörigkeit über mehrere Entscheidungsbäume.
- Diese Art des “demokratischen” Machine Learnings wird auch **Ensemble Learning** genannt.
- Werden mehrere Entscheidungsbäume unterschiedlicher Strukturierung zur gemeinsamen Klassifikation verwendet, wird die Wirkung des Overfittings einzelner Bäume in der Regel reduziert.