



Hochschule für Angewandte Wissenschaften Hamburg
Hamburg University of Applied Sciences

Computational Intelligence

Prof. Dr.-Ing. Sabine Schumann

Fakultät Informatik und Digitale Gesellschaft

Partitioniertes Clustering

Was erwartet Dich in diesem Kapitel?

Clustering

Partitionierendes Clustering

Algorithmen

- k-Means
- k-Means++
- k-Medoid
- Fuzzy-C-Means

Outlier-Detection



Bildquelle: http://static.zoonar.de/img/www_repository3/cf/34/51/10_13e59be813284db2dcd377485c4b5e97.jpg

Was erwartet Dich in diesem Kapitel?

Clustering

Partitionierendes Clustering

Algorithmen

- k-Means
- k-Means++
- k-Medoid
- Fuzzy-C-Means

Outlier-Detection



Bildquelle: http://static.zoonar.de/img/www_repository3/cf/34/51/10_13e59be813284db2dcd377485c4b5e97.jpg

Clustering

- gehört zum unüberwachten Lernen
- auch Segmentierung, Gruppenbildung, Clusteranalyse, ... genannt
- Ziel ist es eine gegebene Datenmenge in Teilmengen (Cluster) zu zerlegen, wobei die Objekte innerhalb eines Clusters „ähnlich“ und mit Objekten anderer Cluster „unähnlich“ sein sollen.
- benötigt wird eine Distanz- oder Abstandsfunktion (siehe [DataMining – Grundlagen](#))
- Grundannahme: **Ähnliche** Daten haben einen **geringen Abstand**

ACHTUNG: Clustering und unüberwachtes Lernen wird oft als Synonym verwendet! Das ist falsch.
Es gibt auch andere Verfahren, die dem unüberwachten Lernen zugeordnet werden.

Clustering / Clusteringanalyse / Dimensionality Reduction

- ähnlich der Klassifikation, Gruppierung anhand von Ähnlichkeiten
- eine gegebene Instanzenmenge E eines Instanzenraumes X wird in Teilmengen (Cluster) aufgeteilt
- Objekte, die zum selben Cluster gehören, sollen möglichst ähnlich (homogen) sein
- Objekte verschiedener Cluster sollen möglichst unähnlich zueinander sein
- Neben der Instanzenmenge werden eine Distanzfunktion zur Bestimmung der Ähnlichkeit zweier Datensätze, sowie eine Qualitätsfunktion, die einen Vergleich von Clusterbildungen ermöglicht, benötigt
- Training anhand von ungelabelten Daten
- Lernen von Strukturen in Daten

► **KEINE** eindeutig korrekte Lösung




Abbildung Cleve, Lämmel: Data Mining, 2014, S. 59

Clusteringverfahren

- Partitionierende Verfahren
- Erwartungsmaximierung
- Hierarchische (agglomerative) Verfahren
- Dichtebasierte Verfahren
- Gitterbasierte Verfahren
- Minimum Spanning Tree (MST und MCST) (Algorithmus von Kruskal)
- künstliche neuronale Netze, bspw. Selbstorganisierende Karten (SOM), neuronale Gase, adaptive Resonanz Theorie (ART-Netze)
- ...

Distanz- und Qualitätsfunktion

Eine gegebene Instanzenmenge E ($E \subseteq X$) soll in **verschiedene Teilmengen** (Cluster) zerlegt werden. Der Abstand der Objekte innerhalb eines Clusters soll kleiner sein als der Abstand zu den Objekten anderer Cluster. Distanzfunktion **dist**(a, b) (siehe [DataMining_Grundlagen](#)):


$$\forall C_i, C_j \text{ mit } i \neq j \in C: \forall v_k, v_l \in C_i, v_m \in C_j: \text{dist}(v_k, v_l) < \text{dist}(v_k, v_m)$$

Eine Qualitätsfunktion beschreibt die Güte des Clusterings:


$$\text{quality}(C = \{C_1 \subseteq E, \dots, C_k \subseteq E\}) \rightarrow \mathbb{R}$$

Meistens basiert die Qualitätsfunktion auf der Abstandsfunktion *dist* bzw. auf einem Ähnlichkeitsmaß *simil*.

Gutes und schlechtes Clustering



schlechtes
Clustering



gutes
Clustering

Cluster


Cluster = Teilmenge

Darstellen lässt sich ein Cluster

- als **Menge** der ihm zugeordneten Individuen,
- als **Vektor der Mittelwerte** der Attribute seiner Individuen (**Centroid**) oder
- durch **einen typischen Vertreter** der Cluster-Elemente (**Medoid**),
- über **Wahrscheinlichkeiten** (jedes Individuum kann verschiedenen Clustern mit einer bestimmten Wahrscheinlichkeit angehören)

Centroid und Medoid

- der Centroid muss nicht in der Datenmenge vorkommen,
- der Medoid muss in der Datenmenge vorkommen
als Medoid kann beispielsweise der Punkt bzw. Datensatz gewählt werden, der am nächsten zum Centroid liegt



Was erwartet Dich in diesem Kapitel?

Clustering

Partitionierendes Clustering

Algorithmen

- k-Means
- k-Means++
- k-Medoid
- Fuzzy-C-Means

Outlier-Detection



Bildquelle: http://static.zoonar.de/img/www_repository3/cf/34/51/10_13e59be813284db2dcd377485c4b5e97.jpg

Partitionierendes Clustering

- es wird eine (beliebige) Anfangspartitionierung von k Clustern gewählt (das kann beispielsweise durch den Centroid passieren)
- aus dieser Anfangspartitionierung werden nun die Objekte schrittweise so zwischen den Clustern geordnet, dass die Güte der Gruppierung sich immer weiter verbessert
- d.h. in jedem Rechendurchlauf für jeden Cluster wird der Centroid neu berechnet
- danach werden alle Objekte demjenigen Cluster zugeordnet, dessen Centroid sie am nächsten sind
- Das Verfahren endet, wenn kein Objekt mehr einem anderen Cluster zugeordnet wird, d.h. die Güte der Partitionierung sich nicht weiter verbessert.
- Partitionierende Clusterverfahren teilen die Eingabedaten in disjunkte Cluster ein, so dass gilt:
 - Jeder Cluster besteht aus mindestens einem Objekt.
 - Jedes Objekt ist höchstens in einem Cluster enthalten.

Mittelpunktverfahren

Der Algorithmus für Mittelpunktverfahren:

1. Erzeuge (zufällig) k **Anfangscluster** C_i . Alle Objekte x aus den Eingabedaten werden (zufällig) einem der Cluster zugeordnet.
2. Bestimme die **Mittelpunkte** $x_1, x_2, \dots, x_k$ der Cluster.
3. Für alle x aus den Eingabedaten:
Weise x demjenigen Cluster C_i zu, von dessen Mittelpunkt x_i es **am wenigsten entfernt** ist.
4. Gehe zu 2, falls mindestens ein x einem anderen Cluster zugewiesen wurde.

Was erwartet Dich in diesem Kapitel?

Clustering

Partitionierendes Clustering

Algorithmen

- k-Means
- k-Means++
- k-Medoid
- Fuzzy-C-Means

Outlier-Detection

Bildquelle: http://static.zoonar.de/img/www_repository3/cf/34/51/10_13e59be813284db2dcd377485c4b5e97.jpg

k-Means / Lloyd-Algorithmus

- partitionierendes Mittelpunktverfahren
- sehr populär, da einfach zu implementieren
- geht auf Hugo Steinhaus (1957), S. P. Lloyd (1957) und J. B. MacQueen (1967) zurück, publiziert 1982
- funktioniert nur für numerische Instanzen
- Anzahl der gesuchten Cluster wird vorgegeben, Mittelpunkte zufällig festgelegt und iterativ adaptiert.
- Der Mittelpunkt pro Cluster wird durch den Centroid (Schwerpunkt) repräsentiert. Der Centroid muss kein Element der Daten sein.


Ablauf:

1. Eingabedaten
2. initiales Clustering
3. Centroid-Bestimmung
4. Neueinteilung der Cluster
5. Gehe zu 3.


k-Means: Beispiel mit $k=3$

k ... Anzahl der gewünschten Cluster, hier 3

Ziel:



kein Cluster



3 disjunkte Cluster

k-Means – Ablauf (1)

Initialisierung durch zufällige Verteilung





Abbildung: Cleve, Lämmel

k-Means – Ablauf (2)

- **Centroide** (Schwerpunkt jedes Clusters) berechnen (muss kein Element des Clusters sein)
- dann neu ordnen durch Abstand zum aktuellen Centroid (bspw. (quadrierte) euklidische Distanz)





Abbildung: Cleve, Lämmel

k-Means – Ablauf (3)

- neuen Centroid berechnen ... usw. usf.
- bis optimale Cluster erreicht sind
(d.h. die Cluster ändern sich nicht mehr)









Abbildung: Cleve, Lämmel

k-Means – Welches k wählen?



k-Means mittels KNIME



k-Means – Vor- und Nachteile

Vorteile

- Anzahl der Iterationen vergleichsweise klein
- einfache Implementierung



populäres Clusteringverfahren

Nachteile

- Anfällig bzgl. Rauschen und Ausreißern, da alle Objekte in die Berechnung des Centroiden eingehen
- Gute initiale Cluster sind oft schwer zu bestimmen
- Ergebnis und Laufzeit sind abhängig von der initialen Zerlegung

Was erwartet Dich in diesem Kapitel?

Clustering

Partitionierendes Clustering

Algorithmen

- k-Means
- k-Means++
- k-Medoid
- Fuzzy-C-Means

Outlier-Detection

Bildquelle: http://static.zoonar.de/img/www_repository3/cf/34/51/10_13e59be813284db2dcd377485c4b5e97.jpg

k-Means versus k-Means++

k-Means

- zufällige Auswahl der anfänglichen Centroiden aus der Instanzenmenge
- dadurch mangelhafte Gruppenzuordnung möglich
- und/oder langsames Konvergieren

k-Means++

- anfängliche Centroiden werden möglichst weit voneinander platziert
- erster Centroid x_1 wird zufällig aus der Instanzenmenge gewählt
- die weiteren Centroiden werden über eine Wahrscheinlichkeitsverteilung, die weiter entfernte Instanzen bevorzugt, zufällig ausgewählt

k-Means++

- erster Centroid x_1 wird zufällig aus der Instanzenmenge $E=\{v_1, \dots, v_n\}$ gewählt
- für alle weiteren Instanzen wird mittels einer Distanzfunktion (meist (quadrierte) euklidische Distanz) die Distanz zum Centroid x_1 ermittelt
- für jede Instanz v wird mittels $\frac{\text{dist}(x_1, v)^2}{\sum_i \text{dist}(x_1, v_i)^2}$ eine Wahrscheinlichkeit berechnet
- mittels dieser Wahrscheinlichkeitsverteilung wird der nächste Centroid zufällig ausgewählt
- dabei bekommen Instanzen, die weiter entfernt sind, eine höhere Wahrscheinlichkeit, als Centroid ausgewählt zu werden, als näher liegende Instanzen
- Das Verfahren wird wiederholt, bis k Centroiden gefunden sind.
Dabei werden die Distanzen von den übriggebliebenen Instanzen zum jeweils nächstliegenden Centroiden ermittelt.
- danach geht es weiter wie bei k-Means

D. Arthur, S. Vassilvitskii: [*k-means++: The Advantages of Careful Seeding*](#).

Proceedings of the 18th annual ACM-SIAM Symposium on Discrete Algorithms. S. 1027-1035,
Society for Industrial and Applied Mathematics, 2007

Was erwartet Dich in diesem Kapitel?

Clustering

Partitionierendes Clustering

Algorithmen

- k-Means
- k-Means++
- k-Medoid
- Fuzzy-C-Means

Outlier-Detection

Bildquelle: http://static.zoonar.de/img/www_repository3/cf/34/51/10_13e59be813284db2dcd377485c4b5e97.jpg

k-Medoid

- Verfahren ähnlich zu k-Means
- als Repräsentant des Clusters wird nicht der Schwerpunkt, sondern der sogenannte **Medoid** verwendet
- Medoid ist **ein Objekt aus den Eingabedaten**
- Das k-Medoid-Verfahren versucht ständig, einen Medoid und einen Nichtmedoid zu tauschen. Der Nichtmedoid wird zum neuen Medoid, der vorherige Medoid zu einem Nichtmedoid. Dabei muss sich natürlich die Qualität der Cluster verbessern.
- bekannteste Algorithmen:
 - **P**artitioning **A**round **M**edoids (PAM)
 - **C**lustering **L**arge **A**pplications based on **RAN**domized **S**earch (CLARANS)

k-Medoid – Algorithmen

Partitioning **A**round **M**edoids (PAM)

- sehr gründliche Suche in den Eingabedaten
- bewertet die Güte des Clusterings für nahezu alle möglichen Kombinationen von Medoiden
- findet gute Cluster
- Nachteil: die Laufzeit steigt mit der Anzahl der Eingabeobjekte PAM daher nur für kleine Mengen zu clusternder Objekte geeignet

Clustering **L**arge **A**pplications based on **R**ANdomized **S**earch (CLARANS)

- weniger gründlich
- effizient
- nicht der komplette Eingaberaum wird abgesucht, sondern zufallsbasiert nur ein Teil der Daten berücksichtigt
- keine wesentlich schlechteren Ergebnisse als PAM

Was erwartet Dich in diesem Kapitel?

Clustering

Partitionierendes Clustering

Algorithmen

- k-Means
- k-Means++
- k-Medoid
- Fuzzy-C-Means

Outlier-Detection

Bildquelle: http://static.zoonar.de/img/www_repository3/cf/34/51/10_13e59be813284db2dcd377485c4b5e97.jpg

Fuzzy-C-Means (1)

- Fuzzy-Clustering-Algorithmus (auch FCM oder Fuzzy-k-Means-Algorithmus genannt)
- „weicher“ Clustering-Algorithmus
- Idee stammt von Joseph C. Dunn, 1973, um k-Means zu verbessern
(*A Fuzzy Relative of the Isodata Process and its Use in Detecting Compact Wellseparated Cluster*, 1973)
- Später von James C. Bezdek verbessert und veröffentlicht
(*Pattern Recognition with Fuzzy Objective Function Algorithms*, 2013)
- Bisher: Objekte wurden **genau einem** Cluster zugewiesen
- Jetzt: Objekte werden Cluster(n) mit einer Wahrscheinlichkeit zugeordnet



Joseph C. Dunn



James C. Bezdek

Bildquellen: <https://math.sciences.ncsu.edu/people/dunn/>
<https://interval.louisiana.edu/IFSA-NAFIPS/KeynoteLectures.html>

Fuzzy-C-Means (2)

„Objekte werden Cluster(n) mit einer Wahrscheinlichkeit zugeordnet“

Beispiel:

- $k=3$ (also 3 Cluster C_1, C_2, C_3),
- die Cluster werden durch ihre Centroiden repräsentiert (x_1, x_2, x_3)
- Objekt O

k-Means

$$\mu_{C_1}(O) = 0$$

$$\mu_{C_2}(O) = 1$$

$$\mu_{C_3}(O) = 0$$

Fuzzy-C-Means

$$\mu_{C_1}(O) = 0,2$$

$$\mu_{C_2}(O) = 0,7$$

$$\mu_{C_3}(O) = 0,1$$

k-Means versus Fuzzy-C-Means

Fuzzy-C-Means:

- Jede Iteration ist rechenaufwendiger,
- Benötigt weniger Iterationen, um zu konvergieren

In der Praxis hat sich gezeigt, dass beide Algorithmen zu sehr ähnlichen Ergebnissen kommen.

S. Ghosh, S.K. Dubey: [*Comparative Analysis of k-means and Fuzzy c-means Algorithms*](#).
IJACSA Vol 4, No 4, 2013, S. 35-39

Hilfe beim Clustern

Güte der Cluster:

- Summe der quadratischen Fehler (SSE – Sum of squared Errors)

Auswahl der optimalen Anzahl an Clustern:


- Elbow Methode
 - graphische Methode
 - Berechnung der SSE über verschiedene k
 - Beginn des schnellsten Anstieges bestimmen

Outlier Detection

Ermittlung von untypischen Daten

Anwendung:

- Entdeckung von Missbrauch bei Kreditkarten, Telekommunikation, ...
- Datenbereinigung (bspw. Messfehler)



Bildquelle: <https://medium.com/@mehulved1503/outlier-detection-and-anomaly-detection-with-machine-learning-caa96b34b7f6>