



Hochschule für Angewandte Wissenschaften Hamburg
Hamburg University of Applied Sciences

Computational Intelligence

Prof. Dr.-Ing. Sabine Schumann

Fakultät Informatik und Digitale Gesellschaft

Dichtebasiertes Clustering



Hochschule für Angewandte Wissenschaften Hamburg
Hamburg University of Applied Sciences

Adaptive Systems and Artificial Intelligence

Prof. Dr.-Ing. Sabine Schumann


Fakultät Informatik und Digitale Gesellschaft

Dichtebasiertes Clustering

Was erwartet Sie in diesem Kapitel?

Dichtebasiertes Clustering

- Idee
- Grundlagen
- DBScan
- Algorithmen



Dichtebasiertes Clustering

Cluster, die stark unterschiedliche räumliche Strukturen haben, können schlecht von den partitionierenden Cluster-Algorithmen erkannt werden


bisher:

Menge von Objekten, die möglichst nah an einem (Mittel)punkt liegen

jetzt:

- Cluster als Gebiete im d -dimensionalen Raum, in denen die Objekte dicht beieinander liegen
- Menge von Objekten, die in einer bestimmten Dichte zueinander liegen werden von anderen Clustern durch Gebiete, in denen die Objekte weniger dicht liegen, getrennt
- die lokale Punktdichte für jedes Objekt im Cluster muss eine vorher festgelegte Minstdichte erreichen (überschreiten)
- die Menge von Objekten, die den Cluster ausmacht, ist räumlich zusammenhängend (im Gegensatz zu k-Means und k-Medoid nicht unbedingt konvex)

Beispiel: Thematische Karten LMU München



Bildquellen: Nasa

J. Sander, M. Ester, X. Xu: Density-Based Clustering in Spatial Databases: The Algorithm GDBSCAN and Its Applications, 1998, S. 14, Figure 13, Visualization of the clustering result for the SEQUOIA 2000 raster data

Idee und Grundlagen

Ausgangspunkt: minimale Dichte erzielen

üblicherweise 2 Parameter:

- $\varepsilon > 0 \in \mathcal{R}$
- MinimumPunkte: wieviele Objekte müssen mindestens in der Nachbarschaft eines Punktes liegen
 $\text{minPts} \in \mathbb{N}$

desweiteren Distanzfunktion dist

- ε -Umgebung eines Punktes p : $N_\varepsilon(p) = \{q \mid \text{dist}(p, q) \leq \varepsilon\}$

DBScan – Algorithmus (1)

1. alle Objekte erhalten die Kennzeichnung *nicht bearbeitet*
2. beliebiges Objekt aus der Menge nehmen und die in der ε –Umgebung liegenden Objekte berechnen
Anzahl der Nachbarschaftsobjekte
 - i. zu klein, den Punkt mit der Kennzeichnung Rauschen (noise) versehen, gehe zu 2
 - ii. ausreichend, es entsteht ein neuer Cluster (Cluster-ID), gehe zu 3
3. Cluster expandieren, in dem die gefundenen Nachbarschaftsobjekte untersucht werden
d.h. rekursives Aufsammeln aller dichteverbundenen Punkte, die in der ε –Umgebung liegen

DBScan – Algorithmus (2)


es gibt 3 Arten von Punkten:

- Punkte die selbst **dicht** sind heißen **Kernobjekte**
(Punkte deren Umgebung die Minimalzahl von dichten Nachbarobjekten erreicht)
- Punkte, die **dichteerreichbar** sind (Dichte-Verbundenheit)
(Objekte, die von einem Kernobjekt erreicht werden, aber keine Kernpunkte sind)
diese Punkte bilden den Rand des Clusters
- Rauschpunkte (**noise**)
(Punkte, die weder dicht noch dichteerreichbar sind)

Beispiel (1)

- $\text{minPts} = 2$
- Euklidische Distanzfunktion

● Auswahl eines Objektes




Beispiel (2)

- $\text{minPts} = 2$
- Euklidische Distanzfunktion

○ Kernpunkt p : $|N_\varepsilon(p)| \geq \text{minPts}$

● dichteerreichbare Punkte




Beispiel (3)

- $\text{minPts} = 2$
- Euklidische Distanzfunktion

○ Kernpunkt p : $|N_\epsilon(p)| \geq \text{minPts}$


● dichteerreichbare Punkte



Beispiel

- $\text{minPts} = 2$
- Euklidische Distanzfunktion

weiter, bis alle Punkte bearbeitet und gekennzeichnet wurden





Besonderheiten dichte-basiertes Clustering

Möglichkeiten:

- es gibt Objekte, die keinem Cluster zugeordnet werden
- es gibt Objekte, die mehreren Clustern zugeordnet werden könnten (dichte-erreichbar)
Zuordnung erfolgt zu **einem** Cluster, in den meisten Algorithmen ist es der Cluster, der als letztes das Objekt erreicht

Vor- und Nachteile

- Effizienz:
 ε -Umgebung meistens effizient auswertbar
 - Einfache Implementierung
 - Keine Anfälligkeit gegenüber Rauschen und Ausreißern
 - Cluster unterschiedlicher Form erkennbar
 - Anzahl der Cluster wird automatisch bestimmt
-
- Parameter (Dichtegrenzwert) ist nicht immer einfach zu bestimmen
(Cluster unterschiedlicher Dichte)



Algorithmen

- DBScan (**D**ensity-**B**ased **S**patial **C**lustering of **A**pplications with **N**oise)
- DENCLUE (**DEN**sity **CLU**st**ER**ing)
Erweiterung von DBScan, weitere: DENCLUE-M, DENCLUE-IM, ...
- OPTICS (**O**rdering **P**oint **T**o **I**dentify the **C**lustering **S**tructure)
- ...