



Hochschule für Angewandte Wissenschaften Hamburg
Hamburg University of Applied Sciences

Computational Intelligence

Prof. Dr.-Ing. Sabine Schumann

Fakultät Informatik und Digitale Gesellschaft

Assoziationsanalyse
A Priori

Von der Warenkorbanalyse zur Assoziationsanalyse

- Scannen von Produkten im Laden mit Hilfe von Lesegeräten durch Barcodetechnik
- dadurch Dokumentation des Kaufverhaltens von Kunden
- diese Daten zur Analyse verwenden, um
 - Waren optimal anzuordnen,
 - die Kunden zu kategorisieren,
 - Welche Produkte sind Ladenhüter?
 - ...



Diese reine Warenkorbanalyse entwickelte sich letztendlich zur (allgemeineren) Assoziationsanalyse.


Assoziationsanalyse

- unüberwachtes Lernen
- Versuch Datenbereiche in den Daten zu finden, in denen mehrere Werte mit hoher Wahrscheinlichkeit gleichzeitig auftreten
 - Ereignis A und B treten oft gemeinsam auf:
 - Finden von Abhängigkeiten von Objekten
 - bspw. „Wer A kauft, kauft auch B“
- Aufstellen von Assoziationsregeln


Korrelation versus Kausalität (1)

Problem


- tatsächliche oder scheinbare Abhängigkeit von Ereignissen
- vgl. Bayessche Netze ...
- Kausalität bei einer Korrelation (A,B) könnte sein:




A verursacht B (1)



B verursacht A (2)



Keine Kausalität, nur zufällige Korrelation in der Stichprobe (3)



Gemeinsame Ursache C (4)

Korrelation versus Kausalität (2)

Probleme:

- Finden zufälliger Korrelationen
Hohe Storchendichte, Hohe Geburtenrate (3,4)
- Verwechseln von Korrelation und Kausalität:
 - **Korrelation** (Gelbe Finger, Lungenkrebs):
Bei gelben Fingern ist mit Lungenkrebs zu rechnen (4)
 - **Kausalität** (Rauchen, Lungenkrebs):
Rauchen verursacht oft Lungenkrebs (1)



Korrelation eignen sich zur Vorhersage

Kausale Beziehungen eignen sich zur Manipulation

Assoziationsanalyse – Verfahren

- A-Priori-Verfahren
- Frequent Pattern Growth
- adaptive Resonanz Theorie (ART-Netze)
- ...

a priori – Algorithmus (1)

- iteratives Verfahren zur Erzeugung von Assoziationsregeln
- es gibt einen durch den Analysten gegebenen minimalen Schwellwert
- Ziel des Verfahrens: *Frequent Itemsets* (Mengen von Objekten) in der Menge aller Items (beliebige Objekte) zu finden, deren relative Häufigkeit (Support) den Schwellwert überschreitet

Beispiel (aus Cleve, Lämmel: Data Mining 2014, S. 175):

Sei der minimale Support mit 2% festgelegt.

Ein Frequent Itemset ist also bspw. bei einer Einkaufsdatenbank die Menge {Bier, Brot, Margarine}, falls diese 3er Kombination in mindestens 2% aller Einkäufe vorkommt.

a priori – Algorithmus (2)

wird in zwei Schritten durchgeführt:

1. Finden von **Frequent Itemsets (FIS)** (Kandidaten) mit ausreichendem Support
 2. Erzeugen von **Assoziationsregeln** aus allen Frequent Itemsets
- Begonnen wird mit **1-elementigen** Frequent Itemsets.
 - Die gefundenen Frequent Itemsets sind die sogenannten Kandidaten.
 - Für jeden Kandidaten wird der Support berechnet und mit dem Schwellwert verglichen, ist der Support kleiner, wird der Kandidat verworfen.
 - Im nächsten Durchlauf werden aus den 1-elementigen **2-elementige** Frequent Itemsets.
 - Im dritten Durchlauf werden aus den 2-elementigen **3-elementige** Frequent Itemsets erzeugt.
 - Usw. usf. bis keine Frequent Itemsets mehr gefunden werden.

a priori – Algorithmus (3)

Ausnutzung der Monotonie-Eigenschaft:

- jede nicht leere Teilmenge eines Frequent Itemsets muss wiederum ein Frequent Itemset sein
- der Support kann also nicht kleiner werden, wenn aus dem Kandidaten ein Item herausgenommen wird
- ebenso kann der Support eines Kandidaten nicht größer werden, wenn ein Item dazu genommen wird.

Beispiel: Erzeugen von 4er Kandidaten.

- 4-elementige Frequent Itemsets können nur aus zwei 3-elementigen Frequent Itemsets entstehen
- bspw. zwei 3-elementige Frequent Itemsets: {A,B,C} und {A,C,D}
 - {A,B,C,D} muss untersucht werden
 - Falls aber {B,C,D} **kein** Frequent Itemset war, dann kann auch {A,B,C,D} **kein** Frequent Itemset sein
- Einsparung von Rechenzeit (**Pruning**).

a priori – Beispiel

Kinobesuche ... wer geht mit wem gern ins Kino?

Kinobesuch	Kinobesucher*in
1	Alice, Charly, Emmy
2	Alice, Emmy, George
3	Alice, Charly, Emmy, Franka, George
4	Alice, Charly, Helene
5	Bob, Charly, Emmy, Franka, George
6	Bob, Charly, Emmy, George, Helene

Schwellwert (geforderter Support): **50%**.

a priori – Beispiel – 1. Iteration

Schwellwert (geforderter Support): 50%.

1. Iteration:
Bilden 1er FIS

Alice	4	66%
Bob	2	33%
Charly	5	83%
Emmy	5	83%
Franka	2	33%
George	4	66%
Helene	2	33%

Kinobesuch	Kinobesucher*in
1	Alice, Charly, Emmy
2	Alice, Emmy, George
3	Alice, Charly, Emmy, Franka, George
4	Alice, Charly, Helene
5	Bob, Charly, Emmy, Franka, George
6	Bob, Charly, Emmy, George, Helene

a priori – Beispiel – 2. Iteration

Schwellwert (geforderter Support): 50%.

2. Iteration:
Bilden 2er FIS

Alice, Charly	3	50%
Alice, Emmy	3	50%
Alice, George	2	33%
Charly, Emmy	4	66%
Charly, George	3	50%
Emmy, George	4	66%

Kinobesuch	Kinobesucher*in
1	Alice, Charly, Emmy
2	Alice, Emmy, George
3	Alice, Charly, Emmy, Franka , George
4	Alice, Charly, Helene
5	Bob , Charly, Emmy, Franka , George
6	Bob , Charly, Emmy, George, Helene

a priori – Beispiel – 3. Iteration

Schwellwert (geforderter Support): 50%.

(1)	Alice, Charly	3	50%
(2)	Alice, Emmy	3	50%
(3)	Alice, George		
(4)	Charly, Emmy	4	66%
(5)	Charly, George	3	50%
(6)	Emmy, George	4	66%

3. Iteration:

Bilden 3er FIS

(1) + (2) + (4)	Alice, Charly, Emmy	2	33%
(1) + (5)	Alice, Charly, George		
(2) + (6)	Alice, Emmy, George		
(4) + (5) + (6)	Charly, Emmy, George	3	50%

Kinobesuch	Kinobesucher*in
1	Alice, Charly, Emmy
2	Alice, Emmy, George
3	Alice, Charly, Emmy, Franka , George
4	Alice, Charly, Helene
5	Bob , Charly, Emmy, Franka , George
6	Bob , Charly, Emmy, George, Helene

Bilden 4er FIS nicht möglich.

Bilden Assoziationsregeln

Erstellen von Assoziationsregeln aus den FIS

- FIS = X wird in 2 nichtleere Teilmengen A und $X \setminus A$ zerlegt
- Dabei ist $A \rightarrow (X \setminus A)$ eine Assoziationsregel, wenn die Regel eine minimale Konfidenz nicht unterschreitet.

$$\text{conf}(A \rightarrow (X \setminus A)) = \frac{\text{support}(X)}{\text{support}(A)} \geq \text{conf}_{\min}$$

- Sowohl der Support, die Konfidenz als auch die Vollständigkeit sind Interessantheitsmaße für Assoziationsregeln.

$$\text{completeness}(A \rightarrow B) = P(A \cup B \mid B) = \frac{\text{support}(A \rightarrow B)}{\text{support}(B)}$$

Assoziationsregeln für unser Beispiel

$X = \{\text{Charly, Emmy, George}\}$

Charly, Emmy, George

1. $A = \{\text{Charly, Emmy}\}$

$$\text{conf}(\{\text{Charly, Emmy}\} \rightarrow \{\text{George}\}) = \frac{\text{support}(\{\text{Charly, Emmy, George}\})}{\text{support}(\{\text{Charly, Emmy}\})} = \frac{3/6}{4/6} = 0,75$$

2. $A = \{\text{Charly, George}\}$

$$\text{conf}(\{\text{Charly, George}\} \rightarrow \{\text{Emmy}\}) = \frac{\text{support}(\{\text{Charly, Emmy, George}\})}{\text{support}(\{\text{Charly, George}\})} = \frac{3/6}{3/6} = 1$$

3. $A = \{\text{Emmy, George}\}$

$$\text{conf}(\{\text{Emmy, George}\} \rightarrow \{\text{Charly}\}) = \frac{\text{support}(\{\text{Charly, Emmy, George}\})}{\text{support}(\{\text{Emmy, George}\})} = \frac{3/6}{4/6} = 0,75$$