AV Programming — Thema 7

Audio- und Video-Inhaltsanalyse

Tóm tắt song ngữ Việt–Đức / Zweisprachige Zusammenfassung (Vietnamesisch–Deutsch)

Mục lục / Inhaltsverzeichnis

- 1. Grundmodell der Inhaltsanalyse (Low/Mid/High-Level Features)
- 2. Fünf Anwendungen der AV-Inhaltsanalyse
- 3. Audio: Onset, Onset-Stärke, librosa
- 4. Beispiel 25 — RMS und spektraler Schwerpunkt
- 5. Beispiel 26 — Grundfrequenz (F0) mit YIN
- 6. Beispiel 27 — Beat- und Tempo-Erkennung
- 7. Beispiel 28 — Shots/Schnitte per Histogrammdifferenz
- 8. Beispiel 29 — Bewegung per Frame-Differenz
- 9. Shots vs. Bewegung — wichtiger Unterschied
- 10. ML-gestützte Inhaltsanalyse: klassisch vs. ML
- 11. Beispiel 30 — YAMNet (Audio-ML)
- 12. Beispiel 31 — torchvision/Faster R-CNN (Video-ML)
- Schnell-Referenz & Zusammenfassung

1. Grundmodell der Inhaltsanalyse

VI Tín hiệu thô (Rohsignal) chưa có 'nội dung' — phải đi qua 3 tầng: Merkmale (đặc trưng mô tả cấu trúc) → Inferenz (suy luận gắn ý nghĩa).

DE Ein Rohsignal ist noch kein Inhalt. Merkmale beschreiben Struktur, nicht Bedeutung. Erst durch Inferenz entsteht eine inhaltliche Aussage.

Pyramide (3 Ebenen):

Ebene	Beispiel Audio	Beispiel Video
Low-Level (aus Abtastwert/Frame, transparent)	RMS, Spektrum, spektrale Differenz	Helligkeit, Farbe, Frame-Differenz
Mid-Level (Merkmale, mittlere Aussagekraft)	Pitch-Verlauf, Beat, Segmentgrenzen	Shots, Keyframes, Tracking-Spuren, Bewegungsmuster
High-Level (Inferenz, schwer nachvollziehbar)	„neuer Abschnitt“, „vermutlich Musik“	„Shot-Wechsel“, „Highlight“

⚠ Ein Peak in der RMS-Kurve bedeutet nur: hier steigt die Signalenergie. Das könnte eine Aktivitätsphase sein — man kann daraus noch nicht auf ein konkretes Ereignis schließen. ML kommt zum Einsatz, wenn solche Zuordnungen nicht mehr mit wenigen expliziten Regeln gelingen.

2. Fünf Anwendungen der AV-Inhaltsanalyse

#	Anwendung	Kurzbeschreibung
1	Automatische Segmentierung von Podcasts	Längere Pausen, Musiktrenner, Sprecherwechsel, starke Energie-/Spektrum-Änderungen → Abschnittsmarken (z. B. 00:00 Begrüßung, 02:15 Nachrichten...)
2	Tempo- und Beat-Erkennung	Regelmäßige Pulse im Signal finden (Beat) → Geschwindigkeit in BPM bestimmen (Tempo)
3	Audio-Fingerprinting	Wiedererkennung eines Audiosignals anhand eines kompakten, charakteristischen Merkmalsprofils — robust gegenüber Störungen, Kompression, kurzen Ausschnitten
4	Shot-Erkennung in Videos	Automatische Identifikation von Schnitt-/Shot-Grenzen zwischen Kameraeinstellungen → Video-Segmentierung, Keyframe-Auswahl, Browsing
5	Objekt- oder Aktivitätserkennung	Objekte lokalisieren (Person, Auto, Ball...) bzw. Handlungen erkennen (läuft, wirft, biegt ab...)

3. Audio-Inhaltsanalyse — Onset & librosa

Begriff	Bedeutung
Onset	Beginn von Klang/Ereignis (Anschlag Klavierton, Trommelschlag, Beginn Silbe...)
Onset-Hinweis	Anzeichen im Signal, dass ein Einsetzen stattfinden könnte (plötzlicher Energie-Anstieg, abrupte spektrale Veränderung)
Onset-Stärke	Wird frameweise berechnet → Kurve über Zeit → Peaks in dieser Kurve = mögliche Onsets

VI librosa là thư viện Python chuyên xử lý tín hiệu audio/âm nhạc — dùng để tải/tiền xử lý audio, tính các Merkmal chuẩn (RMS, Spektrum...), ước lượng Pitch/F0, phân tích Onset/Beat/Tempo. Ưu điểm: hàm gọn, tạo prototype nhanh.

DE librosa ist eine Python-Bibliothek für Audio- und Musiksignalverarbeitung. Vorteil: kompakte Funktionen, schnelle Prototypen, gute Verbindung von Signal, Merkmal und Verfahren.

4. Beispiel 25 — RMS und spektraler Schwerpunkt

Spektraler Schwerpunkt (Spectral Centroid):

$$SC = \left(\sum_{k=0}^{N-1} |X[k]| \cdot f[k] \right) / \left(\sum_{k=0}^{N-1} |X[k]| \right)$$

- k: Frequenzstützpunkte f: Frequenz |X[k]|: Betragsspektrum an dieser Stelle
- Beschreibt die mittlere spektrale Lage der Energie — ein Maß für spektrale Helligkeit (nicht für Tonhöhe!)
- librosa: `spectral_centroid`

```
import matplotlib.pyplot as plt
import librosa

y, sr = librosa.load("audio_Ottos_Mops.wav", sr=None, mono=True)
rms = librosa.feature.rms(y=y)[0]
centroid = librosa.feature.spectral_centroid(y=y, sr=sr)[0]
times = librosa.times_like(rms, sr=sr)
```

⚠ Der spektrale Schwerpunkt ist KEIN Pitch-Maß. Liegt der Schwerpunkt bei 4000 Hz, heißt das NICHT, dass die Stimme auf 4000 Hz „singt“ oder die Grundfrequenz 4000 Hz ist — es heißt nur: die spektrische Energie ist im Mittel in diesem Bereich gewichtet.

VI RMS = đo Aktivität/Năng lượng tín hiệu theo thời gian (giống Quantisierung/Dynamik đã học ở Thema 1). Spektraler Schwerpunkt = đo „độ sáng“ phổ tần (không phải cao độ) — dùng để tìm gợi ý phân đoạn thô, so sánh các đoạn tín hiệu.

DE Typische Nutzung: grobe Segmenthinweise, Vergleich von Signalabschnitten, erster Zugang zur Inhaltsstruktur.

5. Beispiel 26 — Grundfrequenz (F0) mit YIN

- Analysefrage: Welche Tonhöhenstruktur liegt vor? → Übergang von signal-nahen Merkmalen zu strukturbezogener Inferenz
- `librosa.yin` schätzt die Grundfrequenz (F0) frameweise: pro Frame wird untersucht, bei welcher Verzögerung sich das Signal periodisch wiederholt → Periodendauer wird in Hertz umgerechnet

```
f0 = librosa.yin(
y,
fmin=librosa.note_to_hz("C2"),
fmax=librosa.note_to_hz("C7"),
sr=sr
)
```

6. Beispiel 27 — Beat- und Tempo-Erkennung

- Verfahren-Kette: Onset-Stärke → Beat-Tracking → Tempo-Schätzung
- `librosa.beat.beat_track` schätzt das globale Tempo in BPM, basierend auf der Onset-Struktur des Signals — liefert `tempo` und `beat`-Zeitpunkte zurück

```
y, sr = librosa.load("Waltz_for_Ruth.wav", sr=None, mono=True)
tempo, beats = librosa.beat.beat_track(y=y, sr=sr, units="time")
# Geschätztes Tempo (BPM): 107.67
# Beat-Zeitpunkte (s): [17.53, 18.08, 18.62, ...]
```

VI Đây là bước chuyển từ Merkmale (Onset-Stärke) sang Inferenz: từ sự thay đổi tín hiệu, suy luận ra cấu trúc nhịp điệu âm nhạc (musikalische Zeitstruktur).

DE Übergang von Merkmalen zu Inferenz: Aus Signalveränderungen wird auf eine musikalische Zeitstruktur geschlossen.

---

7. Beispiel 28 — Shots/Schnitte per Histogrammdifferenz

VI Khi có 1 cú cắt cảnh thật sự (harter Schnitt), phân bố màu sắc của khung hình thay đổi đột ngột. Ý tưởng: tính Farbverteilung (Histogram) mỗi frame, so với frame trước, chênh lệch lớn = gợi ý có Schnitt.

DE Wenn ein harter Schnitt auftritt, ändert sich das Bild oft sprunghaft. Ansatz: für jedes Frame die Farbverteilung berechnen, mit der des vorherigen Frames vergleichen, große Unterschiede als Hinweis auf einen Schnitt interpretieren.

```
hsv = cv2.cvtColor(frame, cv2.COLOR_BGR2HSV) # BGR -> HSV (Hue, Saturation, Value)
hist = cv2.calcHist([hsv], [0, 1], None, [32, 32], [0, 180, 0, 256]) # Histogramm über
Hue+Saturation
hist = cv2.normalize(hist, hist).flatten() # normalisieren + 2D->1D (flatten) fuer Vergleich
score = cv2.compareHist(prev_hist, hist, cv2.HISTCMP_BHATTACHARYYA)
# Abstandsmass zwischen 2 Histogrammen: klein -> aehnlich, gross -> unaehnlich
```

8. Beispiel 29 — Bewegung per Frame-Differenz

VI Khi có chuyển động, hình ảnh thay đổi theo từng pixel. Ý tưởng: tính giá trị pixel (Graustufen) mỗi frame, so với frame trước, chênh lệch lớn = gợi ý có hoạt động/chuyển động.

DE Wenn eine Bewegung auftritt, ändert sich das Bild. Ansatz: für jedes Bild die Pixelwerte berechnen, mit denen des vorherigen Frames vergleichen, große Unterschiede als Hinweis auf Bewegungsaktivität interpretieren.

```
prev_gray = cv2.cvtColor(prev, cv2.COLOR_BGR2GRAY)
gray = cv2.cvtColor(frame, cv2.COLOR_BGR2GRAY)
diff = cv2.absdiff(gray, prev_gray) # Absolutwert der Differenz pro Pixel
motion_scores.append(diff.mean()) # Mittelwert der Differenzen als Bewegungsmass
```

9. Shots vs. Bewegung — wichtiger Unterschied (oft Klausurfrage!)

Fall	Code 28 (Histogrammdifferenz)	Code 29 (Frame-Differenz)
Person läuft durch Raum	reagiert nur mäßig — Farbverteilung des Bildes bleibt insgesamt ähnlich	reagiert deutlich — viele Pixel ändern sich
Harter Schnitt Innenraum → Strand	reagiert stark — Farbverteilung ändert sich global	reagiert auch stark, aber unspezifisch — fast alle Pixel sind anders

⚠ Code 28 beschreibt eher Änderungen des globalen visuellen Gesamtcharakters eines Frames → geeignet für Hinweise auf Shot-/Schnittwechsel. Code 29 beschreibt eher die direkte Bildänderung zwischen benachbarten Frames → geeignet als einfaches Maß für Bewegungs-/Aktivitätsintensität. Ein hohes Bewegungsmaß allein reicht NICHT aus, um 'relevante Aktivität' zu erkennen (z. B. Kamerabewegung oder Beleuchtungswechsel können ebenfalls hohe Werte erzeugen).

10. ML-gestützte Inhaltsanalyse: klassisch vs. ML

	Klassische Merkmale	ML-gestützte Verfahren
Eigenschaften	transparent, schnell berechenbar	stärkere inhaltliche Zuordnung, oft robuster bei komplexen Aufgaben
Grenzen	begrenzte inhaltliche Aussagekraft	abhängig von Trainingsdaten und Klassenraum, weniger interpretierbar (Black-Box)
Beispiele Audio	RMS, Spektrum, Pitch, Beat	Audio-Event-Klassifikation (YAMNet), Embeddings
Beispiele Video	Histogrammdifferenz, Frame-Differenz	Objekt-, Szenen- und Aktivitätserkennung

VI ML dùng khi Zuordnung (Merkmal → Ý nghĩa) quá phức tạp để viết luật tường minh (regelbasiert) — thay vào đó học từ dữ liệu huấn luyện (Trainingsdaten).

DE Diskussionsimpulse: interpretierbar vs. leistungsstark; wenig Daten vs. Trainingsdatensätze; direkt erklärbar vs. Black-Box-Tendenz; reproduzierbar vs. domänensensitiv.

11. Beispiel 30 — YAMNet (Audio-ML)

- Vortrainiertes Audio-Klassifikationsmodell mit 521 Audioereignisklassen, Grundlage: AudioSet-Klassenraum

- Eingabe: Mono-Audio mit 16 kHz, normiert auf [-1, 1] (gleiches Format wie Speech-to-Text aus Thema 5!)
- Ausgabe: Scores pro Klasse und Zeitabschnitt, Embeddings (gelernte Repräsentationen), internes Spektrogramm

Ablauf: Audio auf 16 kHz/Mono vorbereiten → Modell auf Waveform anwenden → Scores über Zeit mitteln → Top-Klassen bestimmen → Klassenindizes über Klassentabelle in Namen übersetzen.

```
model = hub.load("https://tfhub.dev/google/yamnet/1")
sr, wav = wavfile.read("audio_Ottos_Mops.wav")
wav = wav.astype(np.float32)
if wav.ndim == 2: wav = wav.mean(axis=1) # Stereo -> Mono
wav = wav / np.max(np.abs(wav)) # normieren auf [-1,1]

scores, embeddings, spectrogram = model(wav)
mean_scores = tf.reduce_mean(scores, axis=0)
top5 = tf.argsort(mean_scores, direction="DESCENDING")[:5]
```

⚠ Die Scores sind KEINE Wahrscheinlichkeiten! Größter möglicher Wert wäre 1.0, die Summe aller Scores ergibt nicht 1. Beispiel-Ergebnis 'Ottos Mops': 0 Speech 0.83, 494 Silence 0.11, 3 Narration/monologue 0.02 — der Audioclip wird sehr deutlich als sprachhaltig erkannt, mit ruhigeren/pausenartigen Abschnitten.

12. Beispiel 31 — torchvision/Faster R-CNN (Video-ML)

- Vortrainiertes Objekterkennungsmodell (Faster R-CNN, ResNet50-FPN) aus torchvision — erkennt Objektklassen + Bounding-Boxen pro Frame
- `score_threshold` steuert, ab welcher Modell-Konfidenz eine Erkennung angezeigt wird (z. B. 0.7 vs. 0.5 → niedrigerer Threshold zeigt mehr, aber auch unsicherere Treffer)

```
from torchvision.models.detection import fasterrcnn_resnet50_fpn_v2,
FasterRCNN_ResNet50_FPN_V2_Weights

weights = FasterRCNN_ResNet50_FPN_V2_Weights.DEFAULT
model = fasterrcnn_resnet50_fpn_v2(weights=weights, box_score_thresh=score_threshold)
model.eval()
preprocess = weights.transforms()

img_tensor = torch.from_numpy(frame_rgb).permute(2, 0, 1)
batch = [preprocess(img_tensor).to(device)]
prediction = model(batch)[0]
```

VI Khác với RMS/Histogrammdifferenz (chỉ đo thay đổi tín hiệu thô), model ML này trả về trực tiếp nhãn ngữ nghĩa (person, cow...) kèm Bounding-Box và độ tin cậy — nhưng là Black-Box, phụ thuộc dữ liệu huấn luyện gốc.

DE person: 1.00, cow: 0.87 — Konfidenzwerte je erkanntes Objekt, abhängig vom gewählten score_threshold.

Schnell-Referenz — Beispiel-Codes Thema 7

#	Titel	Kernfunktion
25	RMS und spektraler Schwerpunkt	librosa.feature.rms, librosa.feature.spectral_centroid
26	Grundfrequenz schätzen	librosa.yin
27	Beat- und Tempo erkennen	librosa.beat.beat_track
28	Histogrammdifferenz / Shot-Hinweise	cv2.calcHist, cv2.compareHist (HISTCMP_BHATTACHARYYA)
29	Bewegung via Frame-Differenz	cv2.absdiff auf Graustufenbildern
30	Audio-ML mit YAMNet	tensorflow_hub, 521 Klassen, 16kHz Mono-Input

#	Titel	Kernfunktion
31	Video-ML mit torchvision	fasterrcnn_resnet50_fpn_v2, Bounding-Boxes + Scores

Zusammenfassung

Prinzip	
Audio- und Video-Inhaltsanalyse folgen derselben Grundlogik:	Rohdaten → Merkmale → Inferenz → Anwendung

- Rohdaten sind noch kein Inhalt
- Merkmale machen ausgewählte Strukturen sichtbar (nicht Bedeutung)
- Inferenz verbindet Merkmale mit Deutungen
- klassische Verfahren sind oft transparenter — ML-Verfahren sind oft leistungsfähiger
- fachliche Bewertung bleibt in beiden Fällen notwendig